

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Jakov Kordić

**Primjene generativne umjetne inteligencije
u kreativnom pisanju i generiranju sadržaja**

ZAVRŠNI RAD

Varaždin, 2026.

SVEUČILIŠTE U ZAGREBU
FAKULTET ORGANIZACIJE I INFORMATIKE
V A R A Ž D I N

Jakov Kordić

Matični broj: 0016163751

Studij: Informacijski sustavi

**Primjene generativne umjetne inteligencije u kreativnom pisanju i
generiranju sadržaja**

ZAVRŠNI RAD

Mentor:

Prof. dr. sc. Božidar Kliček

Varaždin, srpanj 2026.

Jakov Kordić

Izjava o izvornosti

Izjavljujem da je moj završni rad izvorni rezultat mojeg rada te da se u izradi istoga nisam koristio drugim izvorima osim onima koji su u njemu navedeni. Za izradu rada su korištene etički prikladne i prihvatljive metode i tehnike rada.

Autor potvrdio prihvaćanjem odredbi u sustavu FOI-radovi

Sažetak

Ovaj završni rad istražuje primjenu generativne umjetne inteligencije u kreativnom pisanju na hrvatskom jeziku. Za potrebe istraživanja izrađen je, očišćen i strukturiran književni korpus sastavljen od autorskih i žanrovskih podkorpusa različitih književnopovijesnih razdoblja i pripovjednih stilova. Podaci su podijeljeni na skup za treniranje i izdvojeni validacijski skup na razini cjelovitih pripovijetki.

Predtrenirani model YugoGPT prilagođen je korpusu QLoRA metodom tijekom deset epoha. Uspoređeni su bazni model i spremljene kontrolne točke, uz jednake parametre generiranja. Evaluacija je obuhvatila vrijednosti gubitka i perpleksiteta, analizu temeljenu na pravilima, procjene pomoću modela umjetne inteligencije, kvalitativnu analizu i korisničku studiju.

Perpleksitet baznog modela na validacijskom skupu iznosio je 12,06, a perpleksitet odabrane kontrolne točke nakon sedme epohe 10,55. Procjene pomoću modela umjetne inteligencije pokazale su najveće poboljšanje zanimljivosti, dok je napredak jezične ispravnosti bio malen. U korisničkoj studiji na 61 potpuno ispunjenom zapisu fino podešeni model ostvario je ukupni prosjek 3,71, naspram 2,86 za bazni model, te je odabran kao bolji u 80,1 % izravnih usporedbi.

Rezultati upućuju na to da fino podešavanje modela YugoGPT može poboljšati koherentnost, književni dojam i čitateljsku privlačnost generiranih nastavaka u promatranom uzorku. Ograničenja ostaju jezične nepravilnosti, povremeni nelogični prijelazi te malen broj promptova i generacija korištenih u završnoj evaluaciji.

Ključne riječi: transformer; YugoGPT; QLoRA; fino podešavanje; obrada prirodnog jezika; generativna umjetna inteligencija; evaluacija; hrvatski jezik; književnost

Sadržaj

1. Uvod.....	1
1.1. Motivacija rada	1
1.2. Ciljevi rada.....	2
1.3. Struktura rada.....	2
2. Metode i tehnike rada	4
2.1. Generativna umjetna inteligencija u kreativnom pisanju.....	4
2.2. Generativni jezični modeli	5
2.3. Transformerska arhitektura i moderni generativni modeli.....	6
2.4. Fino podešavanje i parametarski učinkovita prilagodba	7
2.5. Metode evaluacije generiranog teksta.....	7
2.5.1. Korisničke studije u evaluaciji generiranog sadržaja	8
3. Priprema korpusa i eksperimentalno okruženje	9
3.1. Opis korištenog korpusa	9
3.2. Čišćenje i strukturiranje podataka	11
3.3. Podjela na trening i izdvojeni validacijski skup	11
3.4. Korišteni alati i biblioteke	12
3.4.1. Uporaba alata generativne umjetne inteligencije	14
4. Implementacija i treniranje modela	15
4.1. YugoGPT model	15
4.2. Fino podešavanje modela primjenom QLoRA metode	16
4.3. Hiperparametri treniranja	16
4.3.1. Stopa učenja.....	17
4.3.2. Veličina serije.....	17
4.3.3. Duljina sekvence.....	17
4.3.4. Broj epoha	18
4.4. Generiranje teksta	18
4.4.1. Temperatura	20

4.4.2. Top-k i top-p uzorkovanje.....	20
4.4.3. Penalizacija ponavljanja i zabrana ponavljanja n-grama	21
5. Rezultati i evaluacija modela	22
5.1. Analiza procesa treniranja	22
5.2. Perpleksitet na izdvojenom validacijskom skupu.....	24
5.3. Evaluacija temeljena na pravilima.....	25
5.3.1. Analiza leksičke raznolikosti i ponavljanja	26
5.4. Evaluacija pomoću modela umjetne inteligencije	28
5.4.1. Procjena smislenosti i koherentnosti	28
5.4.2. Procjena stilskog podudaranja	29
5.4.3. Jezična ispravnost	30
5.4.4. Procjena zanimljivosti	30
5.5. Korisnička studija.....	31
5.5.1. Dizajn i provedba korisničke studije	31
5.5.2. Kriteriji i način ocjenjivanja	32
5.5.3. Rezultati korisničke studije.....	33
5.6. Kvalitativna analiza generiranih tekstova	36
5.7. Usporedba baznog i fino podešenog YugoGPT modela	37
5.8. Analiza odabrane konfiguracije i utjecaja broja epoha	38
5.9. Usporedba rezultata s povezanim istraživanjima	39
6. Zaključak	42
Popis literature	44
Popis slika	47
Popis tablica	48
Prilozi	49

1. Uvod

1.1. Motivacija rada

Kreativnost se u istraživačkoj literaturi najčešće povezuje s dvama temeljnim obilježjima: novošću i prikladnošću proizvedenog sadržaja [1]. Razvoj generativne umjetne inteligencije posljednjih je godina značajno promijenio način na koji se pristupa stvaranju i obradi tekstualnog sadržaja. Pojava sustava sposobnih za automatsko sastavljanje duljih tekstova otvorila je nove mogućnosti, ali i pitanja o ulozi takvih sustava u pisanju i obrazovanju [2].

U području kreativnog pisanja generativni modeli više se ne promatraju samo kao tehnički alati, nego i kao sudionici procesa koji mogu utjecati na autorstvo, kreativnu autonomiju i način oblikovanja teksta [3]. Sustavni pregled novijih istraživanja pokazuje da veliki jezični modeli mogu pomoći pri stvaranju ideja, razvoju zapleta, jezičnom dotjerivanju i prevladavanju početne spisateljske blokade [4].

Istraživanja stvarnih korisnika pokazuju da kreativni pisci takve alate uglavnom uključuju selektivno, vodeći računa o autentičnosti, vlastitom stilu i kontroli nad tekстом [5]. Istodobno su uočene koristi poput veće produktivnosti i sigurnosti pri pisanju, ali i rizici povezani sa smanjenjem osjećaja odgovornosti i raznolikosti izraza [6]. Na hrvatskom jeziku dodatni izazov predstavljaju manja količina dostupnih jezičnih resursa i izražena morfološka složenost, zbog čega je opravdano istražiti prilagodbu modela na manjem, kuriranom korpusu [7].

Rezultati dosadašnjih istraživanja nisu potpuno jednolični. Jedno eksperimentalno istraživanje provedeno na studentima pokazalo je da je uporaba ChatGPT-a u uvjetima toga istraživanja bila povezana s nižim rezultatima u pojedinim sastavnicama kreativnog pisanja [8], dok književno usmjerene analize naglašavaju važnost kvalitativne procjene stila, koherentnosti i načina vođenja modela početnim uputama [9]. Usporedbe ljudi, velikih i manjih fino podešenih modela dodatno pokazuju da sama veličina modela nije jedini čimbenik uspješnosti u kratkom kreativnom pisanju [10]. U ovom je radu stoga odabran YugoGPT i kombinirana evaluacija koja obuhvaća kvantitativne pokazatelje, procjene pomoću modela umjetne inteligencije i korisničku studiju.

1.2. Ciljevi rada

Cilj ovog rada je istražiti mogućnosti primjene generativne umjetne inteligencije u kreativnom pisanju i generiranju sadržaja na hrvatskom jeziku korištenjem transformerskih modela. U radu se nastoji analizirati koliko je moguće generirati smislen i stilski uvjerljiv književni tekst korištenjem manjeg književnog korpusa na hrvatskom jeziku.

Jedan od ciljeva rada je izrada i priprema književnog korpusa sastavljenog od autorskih i žanrovskih podkorpusa, uključujući čišćenje, strukturiranje i prilagodbu podataka za treniranje modela. Također se istražuje učinak finog podešavanja predtreniranog modela YugoGPT metodom QLoRA, pri čemu se uspoređuju generacije baznog modela i kontrolnih točaka spremljenih nakon različitog broja epoha.

Posebna pažnja posvećena je odabiru i obrazloženju hiperparametara treniranja i parametara generiranja. Izravno se analizira utjecaj broja epoha usporedbom spremljenih kontrolnih točaka, dok se ostale vrijednosti razmatraju kao dio odabrane konfiguracije uvjetovane dostupnim računalnim resursima. Parametri generiranja održavaju se jednakima za oba modela kako bi se smanjila mogućnost da razlike u rezultatima budu posljedica različitih uvjeta uzorkovanja.

Cilj rada je i evaluacija generiranog sadržaja kvantitativnim i kvalitativnim metodama. Uz vrijednosti gubitka na skupu za treniranje, validacijskog gubitka i perpleksiteta primjenjuju se evaluacija temeljena na pravilima te procjene pomoću modela umjetne inteligencije. Njima se procjenjuju smislenost, koherentnost, jezična ispravnost, stilsko podudaranje i zanimljivost. Korisnička studija obuhvaća smislenost i koherentnost, prirodnost jezika, književni stil s percipiranom originalnošću te ukupnu kvalitetu kao opći čitateljski dojam.

U skladu s navedenim ciljevima, istraživanje je usmjereno na tri povezana pitanja: može li QLoRA fino podešavanje smanjiti perpleksitet na izdvojenim djelima hrvatske književne proze, ostvaruju li generacije fino podešenog modela više korisničke ocjene na odabranim promptovima te kako broj epoha utječe na validacijski gubitak i kvalitativna obilježja generiranih nastavaka.

1.3. Struktura rada

Rad je podijeljen u nekoliko cjelina koje obuhvaćaju teorijski pregled, pripremu podataka, implementaciju modela i analizu rezultata. Nakon uvodnog dijela, u drugom poglavlju prikazane su metode i tehnike rada povezane s generativnom umjetnom

inteligencijom, transformerskim modelima, finim podešavanjem i primjenom generativnih jezičnih modela u kreativnom pisanju i generiranju sadržaja.

Treće poglavlje opisuje proces pripreme književnog korpusa, uključujući čišćenje, strukturiranje i podjelu podataka na trening i izdvojeni validacijski skup, kao i korištene alate i biblioteke. U četvrtom poglavlju prikazani su odabir i učitavanje modela YugoGPT, postupak finog podešavanja metodom QLoRA te obrazloženje korištenih hiperparametara i parametara generiranja teksta.

Peto poglavlje obuhvaća evaluaciju baznog i fino podešenog modela. Prikazani su gubitak na skupu za treniranje, validacijski gubitak i perpleksitet, evaluacija temeljena na pravilima, procjene pomoću modela umjetne inteligencije, korisnička studija i kvalitativna analiza. Uspoređene su kontrolne točke spremljene nakon različitog broja epoha, dok su parametri generiranja zadržani kao jednaki kontrolni uvjeti.

Na kraju rada nalaze se zaključak, popis korištene literature i prilozi s primjerima generiranih tekstova, konfiguracijama modela i dodatnim materijalima korištenima tijekom istraživanja.

2. Metode i tehnike rada

U ovom poglavlju prikazane su metode i tehnike korištene tijekom izrade i provedbe rada. Opisani su osnovni koncepti generativne umjetne inteligencije, generativnih jezičnih modela i transformerske arhitekture na kojoj se temelje moderni sustavi za generiranje teksta. Također su prikazani fino podešavanje predtreniranih modela, parametarski učinkovite metode prilagodbe i metode evaluacije korištene za procjenu kvalitete generiranog sadržaja.

Praktični dio proveden je kroz izradu i ručno čišćenje korpusa, podjelu na skup za treniranje i izdvojeni validacijski skup, QLoRA fino podešavanje modela, spremanje kontrolnih točaka nakon svake epohe, usporedbu kvantitativnih pokazatelja i kvalitativni pregled generacija te završnu evaluaciju odabrane kontrolne točke evaluacijom temeljenom na pravilima, procjenama modela umjetne inteligencije i korisničkom studijom.

2.1. Generativna umjetna inteligencija u kreativnom pisanju

Generativna umjetna inteligencija predstavlja područje umjetne inteligencije usmjereno na stvaranje novog sadržaja na temelju obrazaca naučenih iz podataka. U području kreativnog pisanja kvaliteta takvog sadržaja ne ovisi samo o gramatičkoj ispravnosti, nego i o novosti, prikladnosti, izražajnosti i književnom učinku [1], [9].

Posljednjih godina generativni modeli doživjeli su značajan napredak zahvaljujući razvoju velikih jezičnih modela temeljenih na transformerskoj arhitekturi. Takvi modeli mogu generirati tekst, odgovarati na pitanja, prevoditi sadržaj i prilagođavati se različitim stilovima pisanja. U obrazovnom i kreativnom kontekstu pritom se ističu mogućnosti pomoći pri osmišljavanju ideja, razradi teksta i jezičnom dotjerivanju [2], [4].

Generativni modeli danas se koriste za stvaranje priča, dijaloga, pjesama, članaka i drugih oblika tekstualnog sadržaja. Mogu služiti kao pomoć pri predlaganju ideja, oblikovanju zapleta ili prilagodbi sadržaja određenom stilu. Kreativni pisci pritom ih često uključuju u pojedine faze rada, umjesto da im prepuste cijeli proces [5]. Istraživanja pokazuju i da pomoć modela može povećati produktivnost i samopouzdanje pri pisanju, ali istodobno utjecati na osjećaj odgovornosti i raznolikost konačnih tekstova [6]. U kratkim zadacima kreativnog pisanja čak i manji fino podešeni modeli mogu ostvariti rezultate usporedive s ljudskim autorima i većim modelima [10].

Unatoč velikim mogućnostima, generativni modeli i dalje imaju određena ograničenja. Generirani tekst može sadržavati nelogičnosti, ponavljanja, gramatičke pogreške ili generičke

formulacije. Eksperimentalno istraživanje na studentima zabilježilo je niže rezultate u pojedinim sastavnicama kreativnog pisanja nakon uporabe ChatGPT-a u uvjetima opisanim u tom istraživanju [8], dok rasprave o autorstvu pokazuju da uporaba modela otvara pitanja kreativne autonomije i odgovornosti autora [3].

2.2. Generativni jezični modeli

Generativni jezični modeli predstavljaju modele umjetne inteligencije čija je osnovna zadaća generiranje tekstualnog sadržaja na temelju naučenih statističkih obrazaca. U području automatskog pripovijedanja posebno je zahtjevno održavati temu, odnose među događajima i dugoročniju koherentnost. Hijerarhijsko generiranje, u kojem se prije teksta oblikuje premissa, može poboljšati relevantnost priče [11], dok modeli usmjereni na pretpostavljeno znanje čitatelja mogu pomoći u vođenju radnje prema zadanom cilju [12].

Većina modernih generativnih jezičnih modela temelji se na predviđanju sljedećeg tokena u nizu. Model promatra prethodni kontekst i procjenjuje vjerojatnost mogućih nastavaka, što predstavlja temelj autoregresivnog generiranja teksta [13]. Na primjer, u rečenici:

„Mačka sjedi na ...“

model može predvidjeti nastavke poput „stolu“, „prozoru“ ili „krovu“, ovisno o obrascima koje je naučio tijekom treniranja.

Prije samog treniranja tekstualni podaci prolaze proces tokenizacije, pri čemu se tekst dijeli na manje jedinice nazvane tokeni. Token može predstavljati riječ, dio riječi ili pojedinačni znak. Nakon tokenizacije tokeni se pretvaraju u numeričke reprezentacije koje model može obrađivati, a takav postupak čini osnovu suvremene obrade prirodnog jezika [13].

Generativni jezični modeli treniraju se na velikim količinama tekstualnih podataka kako bi naučili obrasce jezika i odnose između riječi. U generiranju priča sama tečnost nije dovoljna jer je potrebno zadržati vezu s početnim promptom i razvijati događaje u međusobno smislenom redoslijedu. Rezultati hijerarhijskih pristupa pokazuju da odvajanje planiranja premise od generiranja teksta može poboljšati relevantnost i koherentnost nastavka [11].

Razvoj generativnih modela prošao je kroz više faza. Stariji pristupi temeljili su se na statističkim metodama i jednostavnijim neuronskim mrežama, dok se moderni veliki jezični modeli temelje na dubokim neuronskim mrežama i transformerskoj arhitekturi. Upravo su transformeri omogućili značajan napredak u kvaliteti generiranog teksta te razvoj modela sposobnih za generiranje dugih i smislenih tekstualnih cjelina [13].

2.3. Transformerska arhitektura i moderni generativni modeli

Prije razvoja transformerske arhitekture u obradi prirodnog jezika najčešće su se koristile rekurentne neuronske mreže (RNN) i njihove naprednije varijante poput LSTM modela. Takvi modeli obrađivali su tekst sekvencijalno, odnosno riječ po riječ, zbog čega su imali poteškoće s paralelnom obradom podataka i učenjem dugoročnih ovisnosti unutar teksta. Kod duljih sekvenci često je dolazilo do gubitka konteksta i smanjenja kvalitete generiranog sadržaja [13], [14].

Transformerska arhitektura predstavljena je 2017. godine u radu Attention Is All You Need [14]. Za razliku od starijih sekvencijalnih modela, transformer se temelji na mehanizmu pažnje koji omogućuje istodobno razmatranje odnosa između tokena unutar sekvence te učinkovitiju paralelnu obradu.

Jedan od ključnih elemenata transformera jest mehanizam samopažnje (engl. self-attention). Njime se svakom tokenu pridružuju različite težine u odnosu na ostale tokene, što modelu omogućuje stvaranje kontekstualnih reprezentacija i učenje udaljenijih ovisnosti u tekstu [14].

Budući da transformeri obrađuju tokene paralelno, potrebno je modelu dodatno pružiti informaciju o njihovom redoslijedu unutar sekvence. To se postiže pozicijskim reprezentacijama koje svakom tokenu pridružuju informaciju o položaju u tekstu. U modernim generativnim modelima često se primjenjuju rotacijske pozicijske reprezentacije, koje omogućuju učinkovito modeliranje odnosa među tokenima i pri duljim sekvencama [15].

Transformerski modeli najčešće se dijele na enkoderske i dekoderske arhitekture. Enkoderski modeli primarno se koriste za razumijevanje teksta, dok su dekoderski modeli prilagođeni autoregresivnom generiranju. Mistral 7B primjer je učinkovitog dekoderskog modela od približno sedam milijardi parametara, s arhitekturnim rješenjima usmjerenima na bržu obradu i dugi kontekst [15].

YugoGPT, korišten u ovom radu, predtrenirani je bazni model od približno sedam milijardi parametara razvijen za bosanski, hrvatski i srpski jezik. Model se temelji na arhitekturi Mistral 7B i namijenjen je autoregresivnom dovršavanju teksta, zbog čega predstavlja prikladnu osnovu za daljnju prilagodbu hrvatskoj književnoj prozi [16].

2.4. Fino podešavanje i parametarski učinkovita prilagodba

Predtrenirani generativni jezični modeli mogu se dodatno prilagoditi određenom jeziku, stilu ili domeni postupkom finog podešavanja. Tijekom tog procesa model nastavlja učiti na manjem, specijaliziranom skupu podataka, pri čemu se nastoji zadržati prethodno stečeno jezično znanje i istodobno usvojiti obilježja ciljnog korpusa [17], [18].

U ovom radu fino podešavanje primijenjeno je na model YugoGPT korištenjem hrvatskog književnog korpusa. Cilj nije ponovno naučiti jezik od početka, nego prilagoditi postojeći model narativnom stilu, rječniku i strukturi tekstova zastupljenih u korpusu. Takav je pristup prikladan za ograničenu količinu podataka jer model već posjeduje opće jezično znanje.

Kako bi se smanjili zahtjevi za grafičkom memorijom i vremenom treniranja, koriste se parametarski učinkovite metode prilagodbe. LoRA zamrzava težine predtreniranog modela i u odabrane slojeve umeće trenirajuće matrice niskoga ranga [17]. QLoRA dodatno učitava bazni model u četverobitnoj kvantiziranoj reprezentaciji te gradijente prenosi prema LoRA adapterima, čime se znatno smanjuje potrebna memorija [18].

Prednost QLoRA pristupa posebno dolazi do izražaja u okruženjima s ograničenim računalnim resursima. Metoda kombinira četverobitni tip NF4, dvostruku kvantizaciju i optimizatore prilagođene memorijskim vrhovima, a pritom zadržava mogućnost kvalitetne prilagodbe velikih modela [18].

Kod manjeg književnog korpusa potrebno je pratiti gubitak na skupu za treniranje i validacijski gubitak kako bi se uočila stagnacija ili prenaučenosť. Smanjenje gubitka na skupu za treniranje bez odgovarajućeg poboljšanja validacijskog gubitka može značiti da model sve bolje pamti podatke, ali ne poboljšava generalizaciju. Zbog toga se odabir najbolje kontrolne točke ne temelji samo na numeričkim metrikama, nego i na kvalitativnoj usporedbi generiranih nastavaka [32].

U radu se stoga uspoređuje bazni YugoGPT s kontrolnim točkama nastalima tijekom finog podešavanja. Analiza je usmjerena na gramatičku ispravnost, koherentnost, pridržavanje početnog prompta, pojavu ponavljanja i sposobnost preuzimanja književnog stila korpusa.

2.5. Metode evaluacije generiranog teksta

Evaluacija generiranog teksta predstavlja jedan od složenijih problema u području generativne umjetne inteligencije, osobito kada je riječ o kreativnom i književnom sadržaju. Automatske metrike mogu mjeriti pojedina obilježja teksta, ali ne obuhvaćaju uvijek njegovu

književnu i čitateljsku vrijednost. Primjer metrike temeljene na referentnom tekstu jest BERTScore, koji uspoređuje kontekstualne reprezentacije tokena kandidata i referentnog teksta [19].

Tijekom treniranja praćeni su gubitak na skupu za treniranje i validacijski gubitak. Prvi pokazuje uspješnost na podacima korištenima za učenje, a drugi uspješnost na podacima koji nisu korišteni tijekom provedenog finog podešavanja. Njihovo praćenje pomaže u uočavanju prenaučivosti, nedovoljne naučenosti i nestabilnosti treniranja [32].

Uz metrike gubitka koristi se i perpleksitet, jedna od najčešćih metrika u evaluaciji jezičnih modela. Perpleksitet prikazuje koliko je model siguran u svoja predviđanja sljedećih tokena, pri čemu niže vrijednosti uglavnom označavaju bolje rezultate. Ipak, kod generiranja kreativnog sadržaja niža vrijednost perpleksiteta ne mora nužno značiti i kvalitetniji ili zanimljiviji tekst [13].

Klasične metrike ne mogu u potpunosti procijeniti smislenost i stilsku kvalitetu književnog sadržaja, pa su korištene evaluacija temeljena na pravilima i procjene otvorenih odgovora. Ljudske preferencije važan su izvor povratne informacije pri procjeni jezičnih modela [20]. Evaluacija temeljena na pravilima omogućuje ponovljivu analizu formalnih obilježja poput učestalosti riječi, gustoće vokabulara, duljine rečenica i ponavljanja.

Uz taj pristup korištena je evaluacija pomoću modela umjetne inteligencije. Istraživanja modela u ulozi evaluatora (engl. LLM-as-a-judge) pokazuju da snažni jezični modeli mogu pratiti ljudske preferencije, ali upozoravaju i na pristranosti povezane s položajem odgovora, opširnošću i samopreferiranjem [21]. Zbog toga su korišteni jednaki kriteriji, slijepa oznaka izvora i zasebna procjena svakog nastavka.

Važan dio evaluacije predstavlja i kvalitativna analiza generiranih primjera. Generirani tekstovi uspoređuju se prema gramatičkoj ispravnosti, koherentnosti, razini ponavljanja i sposobnosti preuzimanja književnog stila korištenog korpusa. Time se omogućuje detaljnija analiza prednosti i ograničenja pojedinih modela te učinka finog podešavanja i broja epoha na kvalitetu generiranog sadržaja.

2.5.1. Korisničke studije u evaluaciji generiranog sadržaja

Kao dopuna navedenim metodama provedena je korisnička studija. Ljudske procjene omogućuju izravno bilježenje preferencija i dojma kvalitete, što je važno kod otvorenih generativnih zadataka [20]. Sudionicima su predstavljeni tekstovi baznog i fino podešenog modela bez oznake izvora, a kriteriji su obuhvatili smislenost i koherentnost, prirodnost jezika, književni stil s percipiranom originalnošću te ukupnu kvalitetu. Slična istraživanja kratkog

kreativnog pisanja također se oslanjaju na ljudske ocjene gramatičnosti, relevantnosti, kreativnosti i privlačnosti [10].

3. Priprema korpusa i eksperimentalno okruženje

3.1. Opis korištenog korpusa

Za potrebe ovog rada izrađen je objedinjeni heterogeni književni korpus hrvatskih književnih djela dostupnih u javnim digitalnim zbirkama, ponajprije na hrvatskom Wikizvoru [22]. Korpus je oblikovan spajanjem više autorskih i žanrovskih podkorpusa koji obuhvaćaju različita književnopovijesna razdoblja, stilove pisanja, pripovjedne postupke i razine jezične složenosti. Uključeni su tekstovi s obilježjima moderne i simbolističke, realistične i društvene, bajkovite i fantastične te psihološke i eksperimentalne proze. Pri odabiru tekstova vodilo se računa o tome da korpus bude prikladan za prilagodbu modela kreativnom pisanju i generiranju sadržaja na hrvatskom jeziku.

Tablica 1: Struktura objedinjenog heterogenog književnog korpusa.

Podkorpus	Autori	Dominantna obilježja
Moderna i simbolistička proza	Antun Gustav Matoš	atmosferičnost, simbolistički motivi i stilizirani izraz
Realistična i društvena proza	Ksaver Šandor Gjalski; August Šenoa	realistična naracija, dijalog i prikaz društvenih odnosa
Bajkovita i fantastična proza	Ivana Brlić-Mažuranić; Vladimir Nazor	fantastični motivi, bajkovita struktura i jasna fabula
Psihološka i eksperimentalna proza	Dinko Šimunović; August Cesarec; Janko Polić Kamov	psihološko oblikovanje likova, složenija naracija i eksperimentalni postupci

Prije uključivanja tekstova provjeren je njihov autorskopравни status. Prema Zakonu o autorskom pravu i srodnim pravima, autorsko pravo u pravilu traje za života autora i 70 godina nakon njegove smrti, pri čemu se rok računa od 1. siječnja sljedeće godine; nakon isteka roka djelo postaje javno dobro uz obvezu priznanja autorstva i poštovanja djela [23]. Godine smrti autora provjerene su prema mrežnom izdanju Hrvatske enciklopedije [24].

Tablica 2: Provjera autorskopavnog statusa autora uključenih u korpus.

Autor	Godina smrti	Status izvornih djela u 2026.
Antun Gustav Matoš	1914.	Javno dobro
Ksaver Šandor Gjalski	1935.	Javno dobro
Ivana Brlić-Mažuranić	1938.	Javno dobro
August Šenoa	1881.	Javno dobro
Vladimir Nazor	1949.	Javno dobro
Dinko Šimunović	1933.	Javno dobro
August Cesarec	1941.	Javno dobro
Janko Polić Kamov	1910.	Javno dobro

Svi autori uključeni u korpus preminuli su 1949. ili ranije, pa su njihova izvorna književna djela u 2026. izvan zakonskog roka trajanja autorskog prava i imaju status javnog dobra. Pri korištenju su zadržani podaci o autorstvu i izvoru digitalnog prijepisa. Tekstovi su preuzimani s hrvatskog Wikizvora [22], uz dodatnu provjeru dostupnih digitalnih zapisa.

Najveći dio korpusa čine pripovijetke Antuna Gustava Matoša, među kojima su *Cvijet sa raskršća*, *Camao*, *Miš*, *Balkon*, *Moć savjesti*, *Kip domovine leta 188.**, *O tebi i o meni*, *Lijepa Jelena*, *Samotna noć* i *Jesenska idila*. Matoševi tekstovi odabrani su zbog stilističke bogatosti, simbolističkih elemenata, atmosferičnosti i relativno suvremenog književnog izraza.

Drugi važan dio korpusa čine tekstovi Ksavera Šandora Gjalskog iz zbirke *Pod starim krovovima*. U korpus su uključene pripovijetke *Plemenitaši i plemići*, *Perillustis ac generosus Cintek*, *Mlin kod ceste*, *Na Badnjak*, *Starci* i *Idila starog ljeta*. Gjalskijevi tekstovi doprinose realističnoj narativnoj strukturi, razvoju dijaloga i prikazu društvenog konteksta.

U korpus su uključene i priče Ivane Brlić-Mažuranić iz zbirke *Priče iz davnine*: *Šuma Striborova*, *Regoč*, *Sunce djever* i *Neva Nevičica*, *Kako je Potjeh tražio istinu*, *Ribar Palunko* i *njegova žena* te *Bratac Jaglenac* i *sestrica Rutvica*. Ovi tekstovi pridonose bajkovitoj i fantastičnoj dimenziji korpusa te omogućuju modelu učenje jasnije narativne strukture.

Manji dio korpusa čine djela Augusta Šenoe, Vladimira Nazora, Dinka Šimunovića, Augusta Cesarca i Janka Polića Kamova. Od Šenoe su uključeni *Prijan Lovro*, *Prosjak Luka* i *Branka*, od Nazora *Anđeo u zvoniku*, *Čovjek koji izgubi dugme* i *Zmija*, od Šimunovića *Mrkodol*, *Muljika*, *Alkar*, *Duga* i *Đerdan*, od Cesarca *Tonkina jedina ljubav*, a od Kamova *Sloboda*,

Katastrofa, *Žalost* i *Žena*. Ovi autori dodani su kako bi se povećala stilsko raznolikost korpusa i obuhvatili različiti oblici realistične, psihološke i eksperimentalne proze.

Digitalni prijepisi tekstova primarno su preuzeti s hrvatskog Wikizvora [22], a zatim su provjeravani usporedbom s drugim dostupnim digitalnim arhivima i bibliografskim zapisima. Nakon prikupljanja tekstovi su objedinjeni u zajednički korpus i strukturirani pomoću oznaka naslova i sekcija.

3.2. Čišćenje i strukturiranje podataka

Prije treniranja modela bilo je potrebno provesti čišćenje i strukturiranje korpusa. Čišćenje je provedeno ručnim pregledom i uređivanjem tekstova, a ne automatiziranom skriptom. Budući da su tekstovi preuzeti iz različito digitaliziranih izdanja, uključujući zapise dostupne na Wikizvoru [22], korpus je sadržavao OCR i kodne pogreške, nekonzistentne znakove i nepravilnosti nastale tijekom digitalizacije.

Tijekom čišćenja podataka uklonjene su očite OCR pogreške poput raspadnutih riječi, nepravilno prepoznatih znakova i slučajnih artefakata unutar teksta. Također su normalizirani pojedini posebni znakovi i crtice kako bi se smanjile razlike između različitih zapisa istih znakova unutar korpusa. Posebna pažnja posvećena je uklanjanju skrivenih i nekonzistentnih Unicode znakova koji mogu stvarati probleme tijekom tokenizacije i treniranja modela.

Prilikom obrade posebna pažnja posvećena je očuvanju postojeće strukture te rasporeda razmaka i prijeloma redaka unutar tekstova. Budući da su oznake naslova i sekcija korištene za segmentaciju korpusa, izbjegnute su agresivne promjene formatiranja koje bi mogle narušiti strukturu podataka ili otežati kasniju obradu tijekom treniranja modela.

Nakon čišćenja tekstovi su dodatno strukturirani pomoću oznaka poglavlja i sekcija kako bi se omogućila jednostavnija organizacija korpusa, podjela podataka i obrada tijekom treniranja. Takav pristup omogućio je konzistentniji ulazni format podataka te jednostavniju pripremu trening skupa i izdvojenog validacijskog skupa.

3.3. Podjela na trening i izdvojeni validacijski skup

Nakon pripreme korpusa provedena je podjela podataka na trening skup i izdvojeni validacijski skup. Podjela nije napravljena nasumičnim rezanjem teksta, nego na razini cjelovitih pripovijetki kako bi se izbjeglo da se različiti dijelovi istog djela pojave i u trening skupu i u izdvojenom validacijskom skupu. Time se smanjuje mogućnost da se model tijekom evaluacije procjenjuje na tekstovima koje je već djelomično vidio tijekom treniranja.

U izdvojeni validacijski skup uključene su pripovijetke Perillustris ac generosus Cintek, Starci i Idila starog ljeta, dok su preostali tekstovi korišteni za treniranje modela. Odabir tih pripovijetki bio je namjeran jer predstavljaju stilski homogenu, ali sadržajno odvojenu cjelinu iz opusa Ksavera Šandora Gjalskog. Takva validacija omogućuje praćenje prijenosa naučenih književnih obrazaca na cjelovita djela koja nisu korištena tijekom treniranja, a njihov je opseg odgovarao planiranom udjelu korpusa izdvojenom za validaciju.

Konačni skup za treniranje obuhvatio je 35 identificiranih književnih djela organiziranih u 149 tekstualnih sekcija, dok je izdvojeni validacijski skup obuhvatio tri cjelovita djela organizirana u 15 sekcija. Skup za treniranje sadržavao je približno 339.272 riječi, a validacijski skup približno 34.837 riječi, odnosno oko 90,7 % i 9,3 % ukupnog broja riječi. Nakon tokenizacije izrađena su 3.393 bloka za treniranje i 349 blokova za validaciju, svaki duljine najviše 256 tokena.

Za označavanje pojedinih tekstualnih cjelina korištene su oznake naslova i sekcija, primjerice:

Cvijet sa raskršća

Perillustris ac generosus Cintek (1/5)

Takve oznake zadržane su u korpusu jer modelu daju informaciju o početku nove cjeline i olakšavaju organizaciju podataka tijekom treniranja i evaluacije modela.

Nakon podjele podataka izrađene su zasebne datoteke za trening skup i izdvojeni validacijski skup, koje su korištene tijekom tokenizacije, treniranja i evaluacije modela. Takva organizacija omogućila je jednostavniju pripremu podataka i ponovljivost eksperimentalnog postupka.

3.4. Korišteni alati i biblioteke

Za provedbu praktičnog dijela rada korišten je programski jezik Python 3.12, koji zbog velikog broja dostupnih biblioteka predstavlja jedan od najčešćih izbora za razvoj i treniranje modela strojnog učenja te obradu prirodnog jezika.

Razvoj i izvođenje eksperimentalnog dijela rada provedeni su u okruženju Google Colab. Za treniranje modela korištena je pretplata Google Colab Pro, koja omogućuje dulje trajanje sesija i pristup snažnijim grafičkim procesorima u odnosu na besplatnu verziju. Treniranje modela provedeno je na grafičkom procesoru NVIDIA Tesla T4 s 16 GB grafičke memorije, čime je omogućeno izvođenje računalno zahtjevnog postupka finog podešavanja velikog jezičnog modela.

Treniranje svih deset epoha trajalo je približno 72 sata ukupnog izvođenja. Kontrolne točke spremene su nakon svake epohe, što je omogućilo nastavak rada nakon tehničkih prekida i očuvanje dotad postignutih rezultata.

Za implementaciju i treniranje modela korištena je biblioteka PyTorch 2.11.0+cu128, koja omogućuje dinamičko izvođenje tenzorskih operacija, automatsko računanje gradijenata i rad na grafičkim procesorima [26]. Na PyTorchu se temelji i biblioteka Hugging Face Transformers 5.14.1, koja pruža objedinjeno sučelje za učitavanje predtreniranih modela, tokenizatora i postupaka generiranja [27].

Za parametarski učinkovito fino podešavanje modela korištena je biblioteka PEFT 0.19.1 (Parameter-Efficient Fine-Tuning), kojom je implementiran QLoRA (Quantized Low-Rank Adaptation) pristup. Biblioteka Accelerate 1.14.0 korištena je za podršku učitavanju i izvođenju modela na dostupnom uređaju. Umjesto ažuriranja svih parametara modela, ovim se pristupom treniraju dodatni LoRA adapteri, dok izvorni parametri modela ostaju zamrznuti. Na taj se način znatno smanjuju memorijski zahtjevi i omogućuje fino podešavanje velikih jezičnih modela na ograničenoj računalnoj opremi.

Dodatno je korištena biblioteka bitsandbytes 0.50.0, koja omogućuje učitavanje modela uz 4-bitnu kvantizaciju. Time je omogućeno fino podešavanje modela YugoGPT s približno sedam milijardi parametara uz znatno manju potrošnju memorije grafičkog procesora.

Za pripremu i obradu podataka korištene su biblioteke NumPy i Pandas te alati dostupni unutar biblioteke PyTorch. Tekstualni podaci učitani su iz zasebnih datoteka, tokenizirani i podijeljeni u kraće sekvence prikladne za treniranje. Za organizaciju podataka izrađena je vlastita klasa skupa podataka temeljena na klasi Dataset iz modula torch.utils.data. Biblioteka Pandas korištena je za spremanje i obradu rezultata treniranja, dok je NumPy korišten u pojedinim postupcima obrade i analize podataka. Za vizualizaciju promjene vrijednosti funkcije gubitka i perpleksiteta korištena je biblioteka Matplotlib.

Za analizu generiranih tekstova korišten je mrežni alat Voyant Tools, namijenjen čitanju i statističkoj analizi tekstualnih korpusa [28]. U ovom radu upotrijebljen je za analizu učestalosti riječi, leksičke raznolikosti i obrazaca ponavljanja u tekstovima baznog i fino podešenog modela.

Za izradu i provedbu korisničke studije korišten je mrežni alat Google Forms [29]. Alat je omogućio oblikovanje strukturiranog upitnika, primjenu Likertove ljestvice te bilježenje izravne preferencije i neobaveznih komentara ispitanika. Obrazac je konfiguriran tako da ne prikuplja adrese e-pošte ni druge izravne identifikatore ispitanika.

Za organizaciju i statističku obradu podataka prikupljenih korisničkom studijom korišten je Microsoft Excel [31]. U njemu su izračunani deskriptivni pokazatelji, uparene razlike, Wilcoxonov test predznačenih rangova i egzaktni binomni testovi izravnih preferencija.

3.4.1. Uporaba alata generativne umjetne inteligencije

U praktičnom dijelu rada korišteni su Google Gemini 3 Flash [25] i ChatGPT s modelom GPT-5.5 Instant [30]. Njihova je uporaba bila pomoćna i jasno odvojena od treniranja modela YugoGPT i od autorske interpretacije rezultata.

Google Gemini 3 Flash korišten je pri razvoju i prilagodbi pojedinih ćelija Jupyter bilježnice, osobito za prijedloge strukture funkcija, učitavanje kontrolnih točaka, upravljanje memorijom i provjeru sintakse. Svi su prijedlozi ručno pregledani, prilagođeni konkretnom eksperimentalnom postupku i ispitani izvođenjem prije uključivanja u završnu bilježnicu.

GPT-5.5 Instant korišten je isključivo u ulozi evaluatora generiranih nastavaka. Svaki je tekst procijenjen prema unaprijed definiranim kriterijima za smislenost i koherentnost, stilsko podudaranje, jezičnu ispravnost i zanimljivost, uz jednake upute i bez oznake modela koji je tekst proizveo. Konačni odabir metodologije, tumačenje rezultata i tekst rada ostali su odgovornost autora.

4. Implementacija i treniranje modela

U ovom poglavlju opisan je praktični postupak prilagodbe modela YugoGPT za generiranje književnih tekstova na hrvatskom jeziku. Najprije je predstavljen odabrani model i obrazložena njegova prikladnost za zadani problem, nakon čega je opisan postupak finog podešavanja primjenom QLoRA metode.

Posebna je pozornost posvećena odabiru hiperparametara treniranja i njihovoj povezanosti s raspoloživim računalnim resursima, pri čemu se izravno uspoređuje utjecaj broja epoha. Na kraju poglavlja prikazan je postupak generiranja teksta i obrazloženi su parametri uzorkovanja koji su za oba modela korišteni kao konstantni kontrolni uvjeti.

4.1. YugoGPT model

Za eksperimentalni dio rada odabran je predtrenirani model YugoGPT, razvijen za bosanski, hrvatski i srpski jezik [16]. Riječ je o baznom modelu od približno sedam milijardi parametara nastalom nastavkom predtreniranja arhitekture Mistral 7B [15], zbog čega već prije finog podešavanja posjeduje znanje južnoslavenskih jezičnih obrazaca.

U ovom radu korištena je javno dostupna bazna inačica modela YugoGPT s približno sedam milijardi parametara [16]. Budući da je model već tijekom predtreniranja naučio opće zakonitosti jezika, dodatno je prilagođen samo specifičnom zadatku generiranja književnih tekstova.

Model i pripadajući tokenizator učitani su putem biblioteke Hugging Face Transformers [27]. Tokenizator pretvara ulazni tekst u niz tokena koje model obrađuje, dok se tijekom generiranja proizvedeni tokeni ponovno pretvaraju u čitljiv tekst.

Bazni YugoGPT pokazivao je početnu sposobnost generiranja teksta na hrvatskom jeziku, ali su pojedini izlazi sadržavali izražene leksičke, pravopisne i strukturne nepravilnosti. Fino podešavanje stoga nije imalo za cilj ponovno učenje jezika, već prilagodbu modela književnom stilu i obilježjima korpusa korištenog u istraživanju. Odabir modela koji već podržava hrvatski jezik omogućio je usmjeravanje eksperimenta na domensku i stilsku prilagodbu.

4.2. Fino podešavanje modela primjenom QLoRA metode

Kako bi se predtrenirani model YugoGPT prilagodio generiranju književnih tekstova na hrvatskom jeziku, primijenjeno je fino podešavanje QLoRA metodom. LoRA adapteri omogućuju treniranje malog broja dodatnih parametara uz zamrznute težine baznog modela [17], dok QLoRA taj pristup kombinira s četverobitno kvantiziranim baznim modelom [18].

Prije početka treniranja model je učitao u četverobitnoj (4-bit) kvantiziranoj reprezentaciji, čime je dodatno smanjena potrošnja memorije grafičkog procesora. Nakon učitavanja konfigurirani su LoRA adapteri koji su dodani odgovarajućim linearnim slojevima transformera. Tijekom procesa treniranja optimizirani su isključivo parametri tih adaptera, dok su svi ostali parametri predtreniranog modela ostali zamrznuti.

Za provođenje finog podešavanja korištene su biblioteke PEFT i Hugging Face Transformers [27] u okruženju PyTorch [26]. Tijekom treniranja spremljena je kontrolna točka nakon svake epohe, čime je omogućena usporedba razvoja modela i nastavak izvođenja nakon tehničkog prekida.

QLoRA je omogućila fino podešavanje modela YugoGPT na dostupnoj računalnoj opremi bez ažuriranja svih parametara baznog modela. Model je sadržavao ukupno 7.245.139.968 parametara, od kojih je tijekom finog podešavanja optimizirano 3.407.872 parametra LoRA adaptera. Time su memorijska potrošnja i vrijeme treniranja ostali prihvatljivi za eksperimentalno okruženje.

4.3. Hiperparametri treniranja

Hiperparametri predstavljaju skup vrijednosti koje se definiraju prije početka treniranja modela te određuju način na koji će se proces učenja odvijati. Za razliku od parametara modela, koji se tijekom treniranja automatski prilagođavaju, hiperparametri ostaju nepromijenjeni i mogu utjecati na brzinu konvergencije, stabilnost treniranja i konačnu kvalitetu generiranog teksta. U ovom istraživanju izravno je uspoređen utjecaj broja epoha pomoću spremljenih kontrolnih točaka.

Prilikom finog podešavanja modela YugoGPT odabrana je konfiguracija prilagođena ograničenim računalnim resursima i cilju prilagodbe modela korpusu hrvatske književnosti. Stopa učenja, veličina serije i duljina sekvence nisu mijenjane između zasebnih pokretanja, nego se u nastavku obrazlaže njihov odabir i tehnička uloga u provedenom eksperimentu.

4.3.1. Stopa učenja

Stopa učenja određuje veličinu koraka kojim se tijekom optimizacije ažuriraju parametri koji se treniraju. Previsoka vrijednost može uzrokovati nestabilno treniranje, preskakanje povoljnih rješenja i otežanu konvergenciju, dok preniska vrijednost usporava učenje i može zahtijevati veći broj epoha [32].

U ovom radu odabrana je manja stopa učenja od 5×10^{-5} (5e-5) kako bi se smanjio rizik od naglih promjena u ponašanju predtreniranog modela, nestabilnih oscilacija funkcije gubitka i gubitka prethodno naučenih jezičnih obrazaca. Kretanje funkcije gubitka tijekom provedenog treniranja nije pokazivalo nagle oscilacije. Budući da druge stope učenja nisu uspoređene, njihov zaseban utjecaj na konačnu kvalitetu modela nije procijenjen.

4.3.2. Veličina serije

Veličina serije određuje broj primjera koje model obrađuje prije ažuriranja parametara tijekom treniranja. Utječe na potrošnju memorije, brzinu treniranja i varijabilnost procjene gradijenata. Veće vrijednosti zahtijevaju više memorije, dok manje vrijednosti smanjuju memorijske zahtjeve uz nešto veću varijabilnost procjene gradijenata.

U ovom radu korištena je veličina serije po uređaju od jednog primjera. Zbog ograničene memorije grafičkog procesora NVIDIA T4 nije bilo moguće koristiti veću vrijednost. Primijenjena je akumulacija gradijenata kroz osam koraka (`gradient_accumulation_steps = 8`), pa se parametri ažuriraju nakon obrade osam uzastopnih primjera, bez istodobnog smještanja cijele serije u memoriju.

Takva konfiguracija daje efektivnu veličinu serije od osam primjera i omogućuje izvođenje finog podešavanja uz raspoloživu memoriju. Druge veličine serije nisu uspoređene, pa se ne izvodi zaključak o njihovom zasebnom utjecaju na kvalitetu modela.

4.3.3. Duljina sekvence

Duljina sekvence određuje najveći broj tokena koji se istovremeno prosljeđuju modelu tijekom treniranja. Ako tekst sadrži više tokena od zadane duljine, dijeli se na manje cjeline ili se višak tokena odbacuje, dok se kraće sekvence prema potrebi nadopunjuju kako bi sve ulazne sekvence bile jednake duljine.

U ovom radu korištena je duljina sekvence od 256 tokena (`block_size = 256`). Takav odabir predstavlja kompromis između količine konteksta koju model može uzeti u obzir i raspoložive memorije grafičkog procesora. Dulje sekvence omogućile bi modelu pristup većem dijelu teksta odjednom, ali bi istovremeno povećale memorijske zahtjeve i vrijeme treniranja.

Duljina od 256 tokena omogućila je provedbu treniranja bez prekoračenja memorijskih ograničenja NVIDIA T4 grafičkog procesora. Budući da druge duljine sekvence nisu zasebno ispitane, ne može se izdvojeno procijeniti bi li dulji kontekst poboljšao koherentnost generiranih nastavaka.

4.3.4. Broj epoha

Broj epoha određuje koliko puta model prolazi kroz cijeli skup podataka. Veći broj epoha omogućuje dodatnu prilagodbu podacima za treniranje, ali povećava rizik od prenaučivosti, pri kojoj model slabije generalizira na nove primjere.

Treniranje je provedeno tijekom deset epoha. Glavni kriterij za usmjeravanje odabira prema kasnijim kontrolnim točkama bilo je zajedničko kretanje gubitka na skupu za treniranje i validacijskog gubitka. Nakon što su se te vrijednosti u kasnijim epohama stabilizirale, provedena je odvojena preliminarna kvalitativna usporedba na šest promptova koji nisu korišteni u završnoj evaluaciji. Za daljnju je analizu odabrana sedma epoha jer je zadržala povoljne kvantitativne pokazatelje, a njezini su preliminarni nastavci bili stabilniji od nastavaka pojedinih kasnijih epoha.

4.4. Generiranje teksta

Nakon završetka procesa finog podešavanja provedeno je generiranje književnih tekstova na temelju unaprijed definiranih početnih tekstova (engl. prompts; u nastavku: promptovi). Za potrebe kasnije evaluacije korišten je skup od šest promptova različite tematike i narativne strukture. Isti promptovi primijenjeni su na bazni model YugoGPT i odabrani fino podešeni model kako bi se omogućila izravna usporedba generiranih nastavaka.

Promptovi su oblikovani kao počeci kraćih proznih tekstova različite tematike i narativne strukture. Istraživanja automatskog pripovijedanja pokazuju da jasno zadana premisa ili početni plan mogu pomoći modelu u održavanju relevantnosti priče [11]. Zbog toga su promptovi sadržavali prepoznatljiv ambijent, likove ili početni događaj, ali nisu unaprijed određivali završetak.

Prije završne evaluacije provedena je preliminarna kvalitativna usporedba svih spremljenih kontrolnih točaka na zasebnom skupu od šest promptova. Ti su promptovi služili isključivo za kvalitativno razlikovanje kasnijih epoha nakon što je kretanje gubitka na skupu za treniranje i validacijskog gubitka suzilo izbor na stabilnije kontrolne točke. Nisu korišteni u evaluaciji temeljenoj na pravilima, evaluaciji pomoću modela umjetne inteligencije ni u korisničkoj studiji.

Tablica 3: Preliminarni promptovi korišteni pri kvalitativnom odabiru kontrolne točke.

Oznaka	Preliminarni prompt
PP1	Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.
PP2	Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.
PP3	Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.
PP4	Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen. Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.
PP5	Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.
PP6	Uoči svadbe Ana je u majčinoj škrinji pronašla izbljednulu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Izvor: autorski rad.

Za završnu analizu uspješnosti finog podešavanja korišten je drugi, odvojeni skup od šest promptova prikazan u sljedećoj tablici. Na tim su promptovima uspoređeni bazni model i odabrana sedma epoha u svim kasnijim evaluacijskim postupcima.

Tablica 4: Promptovi korišteni u završnoj evaluaciji baznog i fino podešenog modela.

Oznaka	Prompt
P1	Jednom davno, u dalekoj zemlji, živio je kralj poznat po svojoj mudrosti i pravednosti. Jednoga jutra pred vrata njegove palače stigao je nepoznati putnik.
P2	Bijaše kasna jesen. Magla se polako spuštala nad dolinom, a stara kamena kuća stajala je sama na rubu šume. Nitko već godinama nije ulazio u nju, sve dok se jedne večeri iza prozora nije pojavilo slabo svjetlo.
P3	Prije izlaska sunca stari ribar i njegov unuk polako su gurali barku prema mirnom moru. Djed se nasmiješio i rekao:
P4	Mladić je u staroj knjižnici pronašao požutjelo pismo skriveno između dviju knjiga. Kada ga je otvorio i pročitao prvu rečenicu, učinilo mu se da se cijela prostorija promijenila.
P5	Bura je cijelu noć udarala o prozore, a nitko u selu nije slutio što će jutro donijeti. Kada su se prvi stanovnici probudili, na glavnom se trgu nalazio nepoznati predmet.
P6	U malom primorskom mjestu svi su vjerovali da stari svjetionik krije tajnu. Jedne olujne noći dogodilo se nešto što je promijenilo živote svih stanovnika.

Prilikom generiranja korištena je metoda uzorkovanja (`do_sample=True`), koja omogućuje raznovrsnije i kreativnije odgovore u odnosu na deterministički odabir najvjerojatnijeg sljedećeg tokena. Maksimalna duljina nastavka postavljena je na 300 novih tokena (`max_new_tokens=300`). Vrijednost temperature postavljena je na 0,7 (`temperature=0.7`), parametar kumulativnog uzorkovanja na 0,9 (`top_p=0.9`), a broj najvjerojatnijih tokena uključenih u uzorkovanje na 40 (`top_k=40`). Za smanjenje učestalosti neželjenih ponavljanja korišten je faktor penalizacije ponavljanja od 1,1 (`repetition_penalty=1.1`) te zabrana ponavljanja nizova od tri tokena (`no_repeat_ngram_size=3`).

Radi veće ponovljivosti eksperimenta prije svakog generiranja postavljena je početna vrijednost generatora slučajnih brojeva na 42. Za bazni i fino podešeni model korišteni su isti promptovi, jednaki parametri generiranja i jednaka početna vrijednost generatora slučajnih

brojeva. Fiksna početna vrijednost povećava ponovljivost postupka, ali ne može jamčiti potpunu određenost na svakoj kombinaciji hardvera, upravljačkih programa i verzija biblioteka.

4.4.1. Temperatura

Temperatura je parametar koji određuje stupanj nasumičnosti pri odabiru sljedećeg tokena. Niže vrijednosti povećavaju vjerojatnost odabira najizglednijih tokena, dok više vrijednosti povećavaju raznolikost, ali i rizik manje smislenih ili jezično nekonzistentnih nastavaka.

U ovom radu za generiranje teksta korištena je vrijednost temperature 0,7. Vrijednost je odabrana kao srednja postavka između izrazito determinističkog i izrazito nasumičnog generiranja. Budući da druge vrijednosti temperature nisu zasebno uspoređene, njezin pojedinačni doprinos kvaliteti nastavaka nije izolirano procijenjen.

Budući da je cilj rada bio usporediti bazni i fino podešeni model, tijekom evaluacije korištena je ista vrijednost temperature za oba modela. Time je smanjena mogućnost da uočene razlike budu posljedica različitih postavki generiranja.

4.4.2. Top-k i top-p uzorkovanje

Parametri Top-k i Top-p koriste se za ograničavanje skupa mogućih tokena između kojih model odabire sljedeću riječ tijekom generiranja teksta. Njihova je svrha smanjiti vjerojatnost odabira malo vjerojatnih tokena te istodobno očuvati raznolikost i prirodnost generiranog sadržaja.

Parametar Top-k određuje da model pri svakom koraku razmatra samo unaprijed definirani broj tokena s najvećom vjerojatnošću. U ovom radu korištena je vrijednost Top-k = 40, što znači da je odabir sljedećeg tokena ograničen na 40 najizglednijih kandidata. Ta je vrijednost za oba modela korištena kao jednaka kontrolna postavka.

Parametar top-p, poznat kao uzorkovanje jezgre (engl. nucleus sampling), određuje najmanji skup tokena čija ukupna vjerojatnost doseže zadani prag. Korištena je vrijednost top-p = 0,9, pa se veličina skupa kandidata prilagođava raspodjeli vjerojatnosti u svakom koraku.

Kombinacija parametara Top-k = 40 i Top-p = 0,9 korištena je jednako za bazni i fino podešeni model kako bi skup kandidata tijekom uzorkovanja bio određen istim pravilima. Budući da druge kombinacije nisu zasebno uspoređene, njihov pojedinačni utjecaj na kreativnost, koherentnost i stilsku dosljednost nije izravno utvrđen.

4.4.3. Penalizacija ponavljanja i zabrana ponavljanja n-grama

Prilikom generiranja duljih tekstova modeli mogu ponavljati iste riječi, izraze ili rečenice. Radi ograničavanja takvih obrazaca korišteni su penalizacija ponavljanja i zabrana ponavljanja n-grama.

Penalizacija ponavljanja smanjuje vjerojatnost ponovnog odabira već korištenih tokena. Korištena je vrijednost `repetition_penalty` = 1,1 kao blago ograničenje ponavljanja.

Osim toga, korišten je parametar `no_repeat_ngram_size` = 3, koji sprječava ponovno generiranje istih nizova od tri uzastopna tokena. Parametar je za oba modela primijenjen na jednak način radi usporedivosti generiranih nastavaka.

Vrijednosti `repetition_penalty` = 1,1 i `no_repeat_ngram_size` = 3 jednako su primijenjene na oba modela. Budući da nisu provedene generacije bez tih ograničenja, njihov pojedinačni doprinos nije zasebno procijenjen.

5. Rezultati i evaluacija modela

U ovom poglavlju prikazani su rezultati finog podešavanja modela YugoGPT na korpusu hrvatske književnosti. Evaluacijom se nastojalo usporediti bazni i fino podešeni model te odabrati kontrolnu točku koja ostvaruje prikladnu ravnotežu između generalizacije i kvalitete generiranog sadržaja.


Evaluacija je provedena kombiniranjem više postupaka. Najprije su analizirani gubitak na skupu za treniranje, validacijski gubitak i perpleksitet spremljenih kontrolnih točaka. Generirani nastavci zatim su ispitani evaluacijom temeljenom na pravilima, procjenama pomoću modela umjetne inteligencije, korisničkom studijom i kvalitativnim pregledom. Time su obuhvaćena mjerljiva jezična obilježja, smislenost, koherentnost, jezična ispravnost, stilska usklađenost, percipirana originalnost unutar književnog stila, zanimljivost i opći čitateljski dojam.

5.1. Analiza procesa treniranja

Proces finog podešavanja praćen je vrijednostima gubitka na skupu za treniranje i validacijskog gubitka tijekom svih deset epoha. Njihovo kretanje korišteno je za procjenu učenja obrazaca iz korpusa i generalizacije na podatke koji nisu korišteni tijekom treniranja.

Smanjenje gubitka na skupu za treniranje upućuje na usvajanje obrazaca iz podataka, dok validacijski gubitak pokazuje koliko se naučeno znanje prenosi na nove primjere. Stabilizacija obiju vrijednosti bez većeg međusobnog udaljavanja ne pokazuje izraženu prenaučenost.

U ovom radu tijekom prvih epoha zabilježen je kontinuirani pad vrijednosti funkcije gubitka na skupu za treniranje, dok je vrijednost gubitka na izdvojenom validacijskom skupu također pokazivala trend smanjenja. Nakon nekoliko epoha brzina poboljšanja postupno se smanjivala, a vrijednosti validacijskog gubitka počele su stagnirati. Takvo ponašanje upućuje na to da je model usvojio velik dio obrazaca prisutnih u korištenom korpusu te da daljnje treniranje vjerojatno ne bi donijelo značajno poboljšanje vrijednosti promatranih kvantitativnih pokazatelja.



Slika 1: Kretanje vrijednosti funkcije gubitka tijekom treniranja.

Izvor: autorski rad, obrada rezultata treniranja u programskom jeziku Python.

Vrijednost gubitka na izdvojenom validacijskom skupu smanjivala se tijekom početnih epoha, pri čemu je najveći dio poboljšanja ostvaren do približno pete epohe. Nakon toga dolazi do stagnacije, a promjene između susjednih epoha postaju vrlo male. Takav rezultat upućuje na to da nastavak treniranja nakon pete epohe ne donosi značajno poboljšanje sposobnosti generalizacije modela prema promatranom kvantitativnom pokazatelju.

Vrijednost funkcije gubitka nije jedini kriterij za odabir modela namijenjenog kreativnom pisanju. Kretanje gubitka na skupu za treniranje i validacijskog gubitka bilo je glavni razlog za usmjeravanje odabira prema kasnijim kontrolnim točkama, kod kojih su se kvantitativni pokazatelji stabilizirali. Za odabir točne kontrolne točke unutar te skupine pregledani su nastavci svih kasnijih epoha (iza pete) na šest preliminarnih promptova iz Tablice 3.

Preliminarni nastavci ranijih epoha pokazivali su nestabilniji slijed događaja, češće nagle promjene teme i izraženije pravopisne ili kodne deformacije. U kasnijim epohama književni ton i opisnost postaju izraženiji, ali daljnje treniranje nije donosilo jednoliko poboljšanje svih primjera. Sedma epoha na više promptova oblikuje povezane narativne situacije, uvodi likove i dijalog te uglavnom zadržava početni motiv. Primjerice, na promptu o srebrnom ključu razvija motiv skrivenoga blaga, princeze i kletve, dok na promptu o pismu oblikuje prepoznatljivu epistolarnu situaciju i nastavak usmjeren na Franjinu reakciju.

Odabir sedme epohe u odnosu na osmu i devetu posebno podupire šesti preliminarni prompt. Sedma epoha na fotografiju pronađenu uoči svadbe odgovara kratkim, ali tematski


povezanim nastavkom o susretu, ranijem čekanju i sukobu između Ane i druge žene. U osmoj i devetoj epohi isti se početak završava umetkom „Budite prvi koji će recenzirati ‘Zaručnica’ Otkazi odgovor”, koji predstavlja mrežni metapodatak nepovezan s pripovjednom situacijom. Pojava toga artefakta u dvjema kasnijim kontrolnim točkama pokazuje da niži validacijski gubitak ili perpleksitet sami po sebi nisu jamčili stabilniji kreativni nastavak.

Deseta epoha na šestom promptu više ne umeće navedeni mrežni artefakt i razvija dulji nastavak, ali se u njemu pojavljuju referencijalne i vremenske nedosljednosti: Ana se nakon napuštanja ponovno odlučuje udati, odnos s majkom naglo preuzima središte radnje, a završetak uvodi motiv jalovosti bez jasne veze s početnom fotografijom. Slične nepravilnosti vidljive su i u drugim odgovorima desete epohe, primjerice u promjenama roda i broja likova u nastavku o Franjinu pismu. Zbog toga veća duljina i opisnost nisu procijenjene kao dovoljna prednost u odnosu na stabilniju sedmu epohu.

Na temelju zajedničkog kretanja gubitka na skupu za treniranje i validacijskog gubitka izbor je najprije sužen na kasnije epohe, a preliminarna kvalitativna usporedba zatim je korištena za odabir sedme epohe. Takav odabir ne znači da je sedma epoha bila najbolja na svakom pojedinom promptu, nego da je u promatranom preliminarnom skupu pružila najprihvatljiviju ravnotežu između tematske povezanosti, književnog tona i izostanka izraženih mrežnih artefakata. Šest drugih promptova iz Tablice 4 nakon toga je korišteno za završnu evaluaciju baznog i fino podešenog modela.

5.2. Perpleksitet na izdvojenom validacijskom skupu

Za dodatnu kvantitativnu evaluaciju na izdvojenom validacijskom skupu korišten je perpleksitet (engl. perplexity), standardna mjera prediktivne nesigurnosti jezičnog modela [13]. Niža vrijednost znači da model u prosjeku dodjeljuje veću vjerojatnost stvarnim sljedećim tokenima. BERTScore nije korišten jer uspoređuje generirani tekst s referentnim odgovorom [19], a u kreativnom nastavljanju priče ne postoji jedan jedini ispravan nastavak.



Slika 2: Perpleksitet baznog modela i spremljenih kontrolnih točaka po epohama.

Izvor: autorski rad, obrada rezultata evaluacije u programskom jeziku Python.

Na slici je prikazan perpleksitet baznog modela i spremljenih kontrolnih točaka na izdvojenom validacijskom skupu. Bazni model ostvario je 12,06, a vrijednost se nakon prve epohe smanjila na 11,69. Najveći dio poboljšanja ostvaren je u prvih pet epoha. Najniža vrijednost, 10,53, zabilježena je nakon devete epohe, dok je kontrolna točka nakon sedme epohe ostvarila 10,55.

Razlike u perpleksitetu među kasnijim epohama bile su vrlo male, pa ta metrika sama nije bila dovoljna za odabir kontrolne točke namijenjene generiranju kreativnog sadržaja. Glavni kvantitativni razlog za razmatranje kasnijih epoha bilo je stabiliziranje gubitka na skupu za treniranje i validacijskog gubitka, dok je točan odabir sedme epohe dodatno obrazložen preliminarnom kvalitativnom usporedbom nastavaka.

5.3. Evaluacija temeljena na pravilima

Uz funkciju gubitka i perpleksitet provedena je evaluacija generiranih tekstova temeljena na unaprijed određenim formalnim pokazateljima. Takva analiza ne procjenjuje književnu vrijednost teksta, ali omogućuje ponovljivu usporedbu mjerljivih obilježja odgovora baznog i fino podešenog modela.

Analiza je provedena vanjskim alatom Voyant Tools, a obuhvatila je učestalost riječi, ukupan i jedinstven broj riječi, gustoću vokabulara, prosječnu duljinu rečenica i pojavu izraženih obrazaca ponavljanja. Dobiveni pokazatelji korišteni su kao dopuna evaluaciji pomoću modela umjetne inteligencije, korisničkoj studiji i kvalitativnoj analizi.

5.3.1. Analiza leksičke raznolikosti i ponavljanja

Jedan od čestih problema generativnih jezičnih modela jest pojava neželjenog ponavljanja riječi, izraza ili cijelih rečenica tijekom generiranja duljih tekstova. Takvi obrasci narušavaju prirodnost i čitljivost teksta te predstavljaju jedan od pokazatelja kvalitete generiranog sadržaja. Budući da su parametri `repetition_penalty` i `no_repeat_ngram_size` bili jednako postavljeni za oba modela, analiza se usmjerila na provjeru pojavljuju li se u generiranim odgovorima izraženi obrasci ponavljanja i razlikuju li se modeli u leksičkoj raznolikosti.

Za svaki je model u alatu Voyant Tools [28] oblikovan zaseban korpus od odgovora na šest promptova. Analizirani su učestalost riječi, broj različitih riječi, ukupna duljina korpusa, gustoća vokabulara i prosječan broj riječi po rečenici.



Slika 3: Oblak riječi baznog modela YugoGPT.

Izvor: autorska obrada generiranih tekstova u alatu Voyant Tools.

Prosječna duljina rečenica iznosila je 13,7 riječi u oba korpusa. Taj pokazatelj ne pokazuje razliku u osnovnoj duljini rečenica, ali sam po sebi ne omogućuje zaključak o sintaktičkoj složenosti, koherentnosti ili književnom stilu.

5.4. Evaluacija pomoću modela umjetne inteligencije

Uz kvantitativnu analizu i evaluaciju temeljenu na pravilima provedena je evaluacija generiranih tekstova pomoću modela umjetne inteligencije. Istraživanja pristupa u kojem veliki jezični model djeluje kao evaluator pokazuju da takav postupak može pratiti ljudske preferencije, ali i da je osjetljiv na položaj odgovora, opširnost i samopreferiranje [21].

Korišten je GPT-5.5 Instant [30], isključivo u ulozi evaluatora. Za svaki je kriterij zasebno ocijenjeno šest nastavaka baznog i šest nastavaka fino podešenog modela. Tekstovi su dostavljani pojedinačno, bez oznake izvora, uz iste unaprijed definirane upute i ljestvicu od 1 do 5. Nagli završetak uzrokovan ograničenjem na najviše 300 novih tokena nije se automatski kažnjavao.

Procijenjeni su smislenost i koherentnost, stilsko podudaranje, jezična ispravnost i zanimljivost. U potpoglavljima su prikazani posebni kriteriji i dobivene ocjene.

5.4.1. Procjena smislenosti i koherentnosti

Tekstovi su procijenjeni prema logičnom slijedu događaja, povezanosti rečenica i odlomaka, dosljednosti radnje te odsutnosti kontradikcija i nelogičnosti. Ocjena 1 označavala je nepovezan i teško razumljiv tekst, a ocjena 5 potpuno smislen i koherentan nastavak.

Tablica 6: Rezultati procjene smislenosti i koherentnosti.

Redni broj prompta	Bazni model	Fino podešeni model
1	1	4
2	3	4
3	3	3
4	4	4
5	2	2
6	3	2
Prosječna ocjena	2,67	3,17

Fino podešeni model ostvario je prosječnu ocjenu 3,17, a bazni model 2,67. Razlika od 0,50 boda pokazuje umjereno poboljšanje smislenosti i koherentnosti.

Najveća razlika zabilježena je kod prvog prompta, gdje je bazni model zbog metapodataka i deformiranog teksta dobio ocjenu 1, a fino podešeni model ocjenu 4. Kod

drugog prompta fino podešeni model također je bolje održavao početnu atmosferu i slijed radnje.

Ocjene su bile jednake kod trećeg, četvrtog i petog prompta, dok je bazni model bio bolji kod šestog. Prednost fino podešenog modela najjasnije se očitovala u smanjenju potpunog raspada naracije, ali su u pojedinim nastavcima ostali nejasni odnosi među likovima i nagli prijelazi.

5.4.2. Procjena stilskog podudaranja

Stilsko podudaranje procijenjeno je prema pripovjednom stilu, prirodnosti naracije, prikladnosti rječnika, književnom tonu, opisnosti i atmosferi kratke narativne proze. Ocjena 1 označavala je izostanak obilježja književne proze, a ocjena 5 vrlo uvjerljivo stilsko podudaranje.

Tablica 7: Rezultati procjene stilskog podudaranja.

Redni broj prompta	Bazni model	Fino podešeni model
1	1	3
2	3	4
3	3	3
4	2	3
5	3	3
6	3	2
Prosječna ocjena	2,50	3,00

Fino podešeni model ostvario je prosječnu stilsku ocjenu 3,00, a bazni model 2,50. Razlika od 0,50 boda pokazuje umjereno poboljšanje podudaranja s kratkom hrvatskom prozom.

Najveća razlika pojavila se kod prvog prompta: bazni je model izgubio književni ton zbog metapodataka i deformiranog teksta, dok je fino podešeni zadržao dijalog i bajkovite motive. Kod drugog i četvrtog prompta fino podešeni model također je uspješnije održavao opisnost i pripovjedni oblik.

Bazni model ostvario je višu ocjenu samo kod šestog prompta, jer je zadržao oblik pripovijetke, dok je fino podešeni tekst prešao u sažetak i promotivni opis. Nijedan nastavak nije dobio ocjenu 5 zbog gramatičkih nepravilnosti, pojednostavljene sintakse i povremenog prepričavanja umjesto izravnog pripovijedanja.

Fino podešeni model češće zadržava književni ton, opisnost i atmosferu, ali još ne reproducira potpuno stil tekstova iz korpusa.

5.4.3. Jezična ispravnost

Jezična ispravnost procijenjena je prema gramatici, pravopisu, interpunkciji, prirodosti rečenica i uporabi hrvatskog standardnog jezika. Kvaliteta radnje, kreativnost i stilsko podudaranje nisu ulazili u ocjenu.

Ocjena 1 označavala je velik broj pogrešaka koje otežavaju razumijevanje, a ocjena 5 gotovo potpuno gramatički, pravopisno i interpunkcijski ispravan tekst.

Tablica 8: Rezultati procjene jezične ispravnosti.

Redni broj prompta	Bazni model	Fino podešeni model
1	1	3
2	3	3
3	4	3
4	4	4
5	2	3
6	4	3
Prosječna ocjena	3,00	3,17

Fino podešeni model ostvario je prosječnu ocjenu 3,17, a bazni model 3,00. Razlika od 0,17 boda vrlo je mala i ne pokazuje izraženu prednost u gramatičkoj i pravopisnoj ispravnosti.

Fino podešeni model bio je bolji kod prvog i petog prompta, kada je smanjio pojavu oštećenih riječi i izrazitih pravopisnih pogrešaka. Modeli su bili izjednačeni kod drugog i četvrtog prompta, dok je bazni model ostvario višu ocjenu kod trećeg i šestog.

Fino podešavanje nije dosljedno povećalo jezičnu ispravnost svih nastavaka. Njegov je izraženiji doprinos vidljiv u književnom tonu i održavanju pripovjednog oblika, dok su gramatičke, pravopisne i leksičke nepravilnosti ostale prisutne u oba modela.

5.4.4. Procjena zanimljivosti

Zanimljivost je procijenjena pomoću modela umjetne inteligencije umjesto dodatnog proširenja već provedene korisničke studije. Time su svi nastavci analizirani prema jednakim kriterijima koji obuhvaćaju razvoj motiva, sukoba, napetosti i otvorenih pitanja.

Procjena se odnosila na sposobnost privlačenja i održavanja pozornosti, pobuđivanje znatiželje i iščekivanja te želju za nastavkom čitanja. Ocjena 1 označavala je izrazito nezanimljiv, a ocjena 5 vrlo privlačan tekst.

Tablica 9: Rezultati procjene zanimljivosti.

Redni broj prompta	Bazni model	Fino podešeni model
1	2	4
2	2	4
3	2	3
4	3	4
5	3	4
6	4	2
Prosječna ocjena	2,67	3,50

Fino podešeni model ostvario je prosječnu ocjenu 3,50, a bazni model 2,67.

Razlika od 0,83 boda najveća je među četirima procjenama pomoću modela umjetne inteligencije.

Prednost je bila najizraženija kod prvog i drugog prompta, gdje je fino podešeni model razvio pustolovnu radnju i održao tajanstvenu atmosferu. Više ocjene ostvario je i kod trećeg, četvrtog i petog prompta.

Bazni model bio je zanimljiviji samo kod šestog prompta, u kojem je razvio misterij oko svjetionika, dok je fino podešeni model prešao u općeniti sažetak. Fino podešavanje je, dakle, češće povećavalo čitateljsku privlačnost, ali učinak nije bio dosljedan u svakom primjeru.

5.5. Korisnička studija

Iako automatske evaluacije omogućuju dosljednu usporedbu prema unaprijed definiranim kriterijima, ne mogu u potpunosti zamijeniti ljudsku procjenu književnog teksta. Pitanja autorstva, čitateljskog doživljaja i kreativne vrijednosti ostaju povezana s ljudskim tumačenjem [3], a ljudske preferencije važan su izvor podataka u procjeni ponašanja jezičnih modela [20].

S ciljem dopune rezultata automatske evaluacije provedena je korisnička studija u kojoj su sudionici ocjenjivali nastavke kratkih priča generirane baznim i fino podešenim YugoGPT modelom. Sudionicima nije bila poznata pripadnost pojedinog teksta određenom modelu, čime se nastojala osigurati nepristrana procjena kvalitete generiranih nastavaka.

U nastavku su opisani dizajn korisničke studije, kriteriji ocjenjivanja te način analize prikupljenih odgovora.

5.5.1. Dizajn i provedba korisničke studije

Korisnička studija provedena je tijekom srpnja 2026. godine putem mrežnog obrasca izrađenog u alatu Google Forms [29]. Obrazac je konfiguriran tako da ne prikuplja adrese e-pošte ni druge izravne identifikatore ispitanika. Sudjelovanje je bilo dobrovoljno, a prikupljeni podaci korišteni su isključivo u svrhu izrade završnog rada.

Anketa se sastojala od dva dijela. U prvom dijelu prikupljeni su osnovni demografski podaci o ispitanicima, uključujući dob, spol te učestalost korištenja alata generativne umjetne inteligencije. Ti su podaci prikupljeni kako bi se dobio osnovni uvid u strukturu ispitanika i omogućila eventualna usporedba rezultata među različitim skupinama korisnika.

U drugom dijelu ankete ispitanicima je prikazano šest početnih promptova korištenih tijekom generiranja tekstova. Za svaki prompt prikazana su dva anonimno označena nastavka (Odgovor A i Odgovor B), pri čemu je jedan tekst generirao bazni, a drugi fino podešeni YugoGPT model. Raspored A/B uravnotežen je na razini promptova: svaki je model prikazan tri puta kao odgovor A i tri puta kao odgovor B. Isti raspored korišten je za sve ispitanike, dok pripadnost odgovora pojedinom modelu nije bila otkrivena.

Broj promptova ograničen je na šest kako bi se zadržala prihvatljiva duljina ankete i smanjilo opterećenje ispitanika. Budući da je za svaki prompt trebalo pročitati dva nastavka, dodijeliti osam pojedinačnih ocjena i odabrati bolji odgovor, povećanje broja promptova znatno bi produljilo upitnik i moglo smanjiti pažljivost procjenjivanja.

5.5.2. Kriteriji i način ocjenjivanja

Svaki prikazani nastavak ispitanici su ocjenjivali zasebno prema četirima unaprijed definiranim kriterijima: smislenosti i koherentnosti, prirodnosti jezika, književnom stilu i ukupnoj kvaliteti. Prije početka evaluacije svim su ispitanicima prikazana objašnjenja kriterija kako bi se osiguralo njihovo što ujednačenije tumačenje.

Kriterij smislenosti i koherentnosti odnosio se na logičan slijed događaja i povezanost rečenica. Prirodnost jezika obuhvaćala je gramatičku i pravopisnu ispravnost, prirodnost izraza i čitljivost. Književni stil uključivao je originalnost, dojam književnog pripovijedanja, opisnost i atmosferu. Budući da se kreativnost u literaturi uobičajeno povezuje s novošću i prikladnošću [1], rezultat ovoga kriterija tumači se kao pokazatelj percipirane originalnosti, a ne kao objektivna mjera tekstualne novosti. Ukupna kvaliteta predstavljala je opći čitateljski dojam.

1 – vrlo loše

2 – loše

3 – zadovoljavajuće

4 – dobro

5 – izvrsno

Viša vrijednost na ljestvici označavala je pozitivniju procjenu promatranog kriterija. Ispitanici su morali odabrati jednu ocjenu za svaki od četiriju kriterija i za svaki prikazani tekst, čime je za jedan par nastavaka prikupljeno ukupno osam pojedinačnih ocjena.

Pri procjeni prirodnosti jezika ispitanicima je naglašeno da starije, arhaične ili književno stilizirane izraze ne trebaju automatski smatrati pogreškama ako su pravilno upotrijebljeni i odgovaraju književnom kontekstu. Kao primjeri navedeni su izrazi „bijaše“, „ne bijaše“, „reče“, „dođosmo“ i „ugledah“. Također su upozoreni da tekstovi mogu završiti naglo zbog ograničenja generiranja na najviše 300 novih tokena te da sam prekid teksta ne trebaju uzimati u obzir pri dodjeljivanju ocjene.

Nakon ocjenjivanja oba nastavka za pojedini prompt ispitanici su morali odabrati koji im je odgovor bolji. Time je, uz pojedinačne numeričke ocjene, prikupljen i podatak o izravnoj preferenciji između baznog i fino podešenog modela. Ispitanicima je ponuđena i mogućnost ostavljanja neobaveznog komentara kojim su mogli obrazložiti zašto im se odabrani odgovor više svidio. Ti su komentari korišteni kao kvalitativna dopuna rezultatima dobivenima Likertovom ljestvicom.


5.5.3. Rezultati korisničke studije

U korisničkoj studiji prikupljen je 61 potpuno ispunjen odgovor. Budući da su sva pitanja s numeričkim ocjenama i izravnim odabirom boljeg odgovora bila obvezna, u analizu su uključeni svi zapisi. Bazni model bio je prikazan redoslijedom A–B–A–B–A–B, dok je fino podešeni model bio prikazan redoslijedom B–A–B–A–B–A, čime je provedena uravnoteženost oznaka na razini promptova.

Najveći dio uzorka činili su ispitanici u dobi od 21 do 25 godina, njih 35 ili 57,4 %. U istraživanju su sudjelovala 33 muškarca i 28 žena. Alate generativne umjetne inteligencije često je koristio 31 ispitanik, a svakodnevno njih 14, što pokazuje da je većina uzorka već imala određeno iskustvo s takvim sustavima.

Dob

61 responses




Slika 5: Struktura ispitanika prema dobi.

Izvor: autorska obrada rezultata korisničke studije u alatu Google Forms.

Spol

61 responses




Slika 6: Struktura ispitanika prema spolu.

Izvor: autorska obrada rezultata korisničke studije u alatu Google Forms.

Koliko često koristite alate umjetne inteligencije (ChatGPT, Gemini, Copilot...)?

61 responses



Slika 7: Učestalost korištenja alata umjetne inteligencije među ispitanicima.

Izvor: autorska obrada rezultata korisničke studije u alatu Google Forms.

Za svaki je kriterij najprije izračunana prosječna ocjena pojedinog ispitanika za šest nastavaka baznog i šest nastavaka fino podešenog modela. Budući da su isti ispitanici ocjenjivali oba modela, razlike su analizirane Wilcoxonovim testom predznačenih rangova za uparene uzorke. U Tablici 10 prikazane su aritmetičke sredine (M), standardne devijacije (SD) i prosječne razlike između modela. Izračuni i organizacija rezultata provedeni su u Microsoft Excelu [31].

Tablica 10: Rezultati korisničkih ocjena prema kriterijima.

Kriterij	Bazni model M (SD)	Fino podešeni model M (SD)	Razlika	p
Smislenost i koherentnost	2,81 (0,55)	3,76 (0,75)	0,95	< 0,001
Prirodnost jezika	2,92 (0,55)	3,67 (0,64)	0,75	< 0,001
Književni stil	2,87 (0,50)	3,70 (0,66)	0,84	< 0,001
Ukupna kvaliteta	2,82 (0,48)	3,72 (0,69)	0,90	< 0,001
Ukupni prosjek	2,86 (0,48)	3,71 (0,67)	0,86	< 0,001

Na šest korištenih promptova i dvanaest fiksnih generiranih nastavaka fino podešeni model ostvario je višu prosječnu ocjenu u svim promatranim kriterijima. Najveća razlika zabilježena je kod smislenosti i koherentnosti, gdje je prosjek povećan s 2,81 na 3,76. Slijedi ukupna kvaliteta s razlikom od 0,90 boda, književni stil s razlikom od 0,84 boda te prirodnost jezika s razlikom od 0,75 boda. Ukupni prosjek svih ocjena iznosio je 2,86 za bazni i 3,71 za fino podešeni model. Sve su uparene razlike bile statistički značajne uz $p < 0,001$.

Rezultat književnog stila ujedno obuhvaća percipiranu originalnost, opisnost, atmosferu i dojam književnog pripovijedanja. Viša ocjena fino podešenog modela stoga pokazuje da su ispitanici njegove nastavke doživjeli književno uvjerljivijima i originalnijima, ali taj nalaz ostaje subjektivna procjena čitatelja unutar šireg kriterija književnog stila.

Osim ukupnih rezultata, analizirane su prosječne ocjene i izravne preferencije za svaki prompt. Prosjek po promptu izračunan je objedinjavanjem četiriju kriterija za sve ispitanike. U posljednjem stupcu Tablice 11 prikazan je broj i udio odabira fino podešenog modela kao boljeg odgovora.

Tablica 11: Ocjene i izravne preferencije prema promptovima.

Prompt	Bazni prosjek	Fino podešeni prosjek	Razlika	Prednost fino podešenog modela
P1	1,56	3,89	2,33	56/61 (91,8 %)
P2	2,88	3,80	0,92	49/61 (80,3 %)
P3	2,91	3,60	0,69	53/61 (86,9 %)
P4	3,14	3,97	0,83	55/61 (90,2 %)
P5	3,16	3,67	0,51	47/61 (77,0 %)
P6	3,49	3,35	-0,14	33/61 (54,1 %)
Ukupno	2,86	3,71	0,86	293/366 (80,1 %)

Najveće poboljšanje ostvareno je kod prvog prompta, pri kojem je prosječna ocjena povećana za 2,33 boda, a fino podešeni odgovor odabralo je 56 od 61 ispitanika. Fino podešeni model ostvario je jasnu prednost i kod drugog, trećeg, četvrtog i petog prompta. Egzaktni binomni test pokazao je da je udio preferencija za fino podešeni model kod prvih pet promptova bio značajno veći od 50 % ($p < 0,001$).

Šesti prompt predstavlja iznimku. Bazni model ostvario je nešto višu prosječnu ocjenu, 3,49 prema 3,35, dok je fino podešeni odgovor ipak odabralo 54,1 % ispitanika. Ta podjela nije bila statistički značajna ($p = 0,609$), što pokazuje da u tom primjeru nije postojala jasna zajednička preferencija. Ukupno je u 366 pojedinačnih usporedbi fino podešeni model odabran 293 puta, odnosno u 80,1 % slučajeva.

Kako bi se provjerilo u kojoj mjeri izrazito oštećen prvi izlaz baznog modela utječe na ukupnu razliku, provedena je dodatna analiza preostalih pet promptova. I nakon njegova izuzimanja prosječna prednost fino podešenog modela iznosila je 0,56 boda, a model je odabran kao bolji u 237 od 305 preostalih usporedbi, odnosno u 77,7 % slučajeva. Ukupna prednost stoga nije posljedica isključivo prvog izlaza, iako je taj primjer povećao njezinu veličinu.

Na šest korištenih promptova i po jednoj generaciji za svaki model fino podešeni model ostvario je više korisničke ocjene i bio češće odabran kao bolji. Rezultat šestog prompta istodobno pokazuje da poboljšanje nije dosljedno u svakom primjeru.

5.6. Kvalitativna analiza generiranih tekstova

Kvalitativna analiza provedena je na istih dvanaest nastavaka korištenih u evaluaciji pomoću modela umjetne inteligencije i korisničkoj studiji. Razmotreno je i 60 neobaveznih

komentara ispitanika, grupiranih prema smislenosti, zadržavanju teme, prirodnosti jezika, književnom dojmu i zanimljivosti.

Najveća razlika vidljiva je kod prvog prompta. Bazni model prelazi u metapodatke i deformirane riječi, dok fino podešeni zadržava bajkovitu situaciju, uvodi dijalog i razvija priču unutar priče. Kod drugog prompta fino podešeni model također bolje održava atmosferu napuštene kuće, bez naglog prijelaza na nepovezanu radnju. Komentari ispitanika u oba su slučaja naglašavali smislenost, zanimljivost i lakše praćenje.

Četvrti prompt ostvario je najviši prosjek fino podešenog modela jer je motiv pisma razvijen u obiteljsku tajnu i planirani bijeg. U petom promptu poboljšanje je bilo manje: model je stvorio upečatljivo biće i prijeteću atmosferu, ali nije potpuno razjasnio odnose među likovima i događajima. Treći prompt također je pokazao umjereniju prednost uz prisutne jezične pogreške.

Šesti prompt ostao je iznimka. Bazni model zadržao je izravno pripovijedanje i razvio susret pokraj svjetionika, dok je fino podešeni odgovor nalikovao sažetku. Komentari su zato bili podijeljeni i nisu pokazali jasnu zajedničku preferenciju.

Fino podešeni model češće održava temu, oblikuje atmosferu i razvija početni motiv. Glavne slabosti ostaju lokalne gramatičke pogreške, nepravilno oblikovane riječi, nejasni odnosi među likovima i povremeni prijelaz iz pripovijedanja u sažetak.

5.7. Usporedba baznog i fino podešenog YugoGPT modela

Usporedba rezultata različitih evaluacijskih postupaka pokazuje da se prednost fino podešenog modela pojavljuje u većini promatranih pokazatelja, ali da veličina poboljšanja ovisi o tome koje se svojstvo teksta procjenjuje. Budući da metrike imaju različito značenje i različite ljestvice, njihove se vrijednosti ne uspoređuju međusobno, nego samo između modela unutar istog pokazatelja.

Tablica 12: Sažetak usporedbe baznog i fino podešenog modela.

Pokazatelj	Bazni model	Fino podešeni model	Promjena
Perpleksitet na validacijskom skupu	12,06	10,55	-1,51
Gustoća vokabulara	0,650	0,624	-0,026
AI – smislenost i koherentnost	2,67	3,17	+0,50
AI – stilsko podudaranje	2,50	3,00	+0,50
AI – jezična ispravnost	3,00	3,17	+0,17
AI – zanimljivost	2,67	3,50	+0,83
Korisnička studija – ukupni prosjek	2,86	3,71	+0,86

Perpleksitet odabrane kontrolne točke nakon sedme epohe iznosio je 10,55, što je za 1,51 manje od vrijednosti baznog modela. Relativno smanjenje iznosi približno 12,5 % i pokazuje bolju prilagodbu obrascima izdvojenog validacijskog skupa.

Analiza temeljena na pravilima nije pokazala izraženu promjenu gustoće vokabulara ni prosječne duljine rečenica. Fino podešeni model proizveo je više riječi i veći apsolutni broj jedinstvenih riječi, ali nešto nižu gustoću vokabulara. Taj nalaz upućuje na to da se poboljšanja u koherentnosti i književnom dojmu ne mogu objasniti samo udjelom različitih riječi.

Evaluacija pomoću modela umjetne inteligencije pokazala je u analiziranom uzorku bolje rezultate fino podešenog modela u sva četiri kriterija, osobito u zanimljivosti, dok je razlika u jezičnoj ispravnosti bila mala. Korisnička studija pokazala je izraženiju prednost: fino podešeni model bio je bolje ocijenjen u svim kriterijima i odabran u 80,1 % izravnih usporedbi.

Nalazi evaluacije pomoću modela umjetne inteligencije i korisničke studije uglavnom su usklađeni. Oba postupka prepoznala su najveću prednost kod prvog i slabiji rezultat kod šestog prompta. Razlika je vidljiva u procjeni jezika: evaluator je strože vrednovao gramatičku i pravopisnu ispravnost, dok su ispitanici procjenjivali širi dojam prirodnosti i čitljivosti.

U analiziranom uzorku fino podešavanje najviše je poboljšalo stabilnost naracije, tematsku povezanost, književni ton i čitateljsku privlačnost. Pojedini nastavci ipak su zadržali jezične pogreške, nelogične prijelaze ili promjenu pripovjednog oblika, pa kvalitetan izlaz nije zajamčen za svaki prompt.

5.8. Analiza odabrane konfiguracije i utjecaja broja epoha

Broj epoha bio je jedini hiperparametar izravno uspoređen pomoću spremljenih kontrolnih točaka. Stopa učenja, veličina serije, duljina sekvence, QLoRA konfiguracija i parametri generiranja ostali su nepromijenjeni, pa se njihov pojedinačni doprinos ne može izdvojiti.

Odabrana je razmjerno mala stopa učenja, 5×10^{-5} , s namjerom smanjenja rizika od naglih promjena parametara, nestabilnog kretanja funkcije gubitka i narušavanja prethodno naučenih obrazaca [32]. Veličina serije od jednog primjera uz akumulaciju gradijenata kroz osam koraka, duljina sekvence od 256 tokena i četverobitna kvantizacija odabrane su zbog memorijskih ograničenja grafičkog procesora NVIDIA T4.

Perpleksitet se smanjio s 12,06 za bazni model na 11,69 nakon prve, 11,05 nakon druge i 10,73 nakon treće epohe. Do pete epohe pao je na 10,57, nakon čega su razlike

postale vrlo male. Najniža vrijednost od 10,53 zabilježena je nakon devete epohe, a u desetoj je porasla na 10,57.

Najveći dio kvantitativnog poboljšanja ostvaren je u prvih pet epoha. Kasnije vrijednosti ne pokazuju stabilan napredak, iako nije zabilježen nagli rast validacijskog gubitka koji bi upućivao na izrazito prenaučavanje.

Za završnu evaluaciju odabrana je kontrolna točka nakon sedme epohe. Glavni kriterij za sužavanje odabira bilo je zajedničko kretanje gubitka na skupu za treniranje i validacijskog gubitka, koji su se nakon ranijih epoha postupno stabilizirali. Perpleksitet sedme epohe iznosio je 10,55, samo 0,02 više od najmanje zabilježene vrijednosti, pa razlika između kasnijih kontrolnih točaka nije bila dovoljna za samostalan izbor. Točan odabir sedme epohe stoga je dopunjen preliminarnom kvalitativnom usporedbom na šest promptova koji nisu korišteni u završnoj evaluaciji. Posebno je informativan bio šesti preliminarni prompt o fotografiji pronađenoj uoči svadbe. Sedma epoha proizvela je kratak nastavak koji je ostao vezan uz zadani odnos likova i nije sadržavao vanjske metapodatke. Nasuprot tome, osma i deveta epoha nakon početka nastavka umetnule su web-artefakt „Budite prvi koji će recenzirati ‘Zaručnica’ Otkazi odgovor“, dok je deseta epoha razvila dulji tekst s izraženim gramatičkim i referencijalnim nedosljednostima. Taj primjer, zajedno s pregledom ostalih preliminarnih nastavaka, upućivao je na to da dodatne epohe nisu donosile dosljedno kvalitativno poboljšanje, pa je sedma epoha odabrana kao uravnotežena kontrolna točka za daljnju analizu.

Kontrolne točke nakon osme, devete i desete epohe nisu pokazale dosljedno kvalitativno poboljšanje. U primjerima osme epohe pojavljuju se deformirane riječi, nagli prijelaz iz radnje o napuštenoj kući na nepovezanu epizodu s vukovima te promotivni sažetak umjesto pripovjednog nastavka. U devetoj epohi zabilježene su nedosljednosti u ulogama i rodu likova, nagle promjene prizora te vrlo kratak nastavak šestog prompta. U desetoj epohi ostaju gramatičke nedosljednosti, promjena roda pripovjednog subjekta u četvrtom promptu i ponovno vrlo kratak šesti nastavak. Ti primjeri pokazuju da neznatno niži perpleksitet kasnijih kontrolnih točaka sam po sebi nije značio stabilniju kvalitetu generiranog teksta.

Parametri generiranja bili su jednaki za oba modela. Jedna generacija po promptu i jedna početna vrijednost generatora slučajnih brojeva povećavaju ponovljivost usporedbe, ali ne prikazuju punu varijabilnost stohastičkog generiranja.

Rezultati se odnose na jednu konfiguraciju, šest promptova i ograničen broj generiranih primjera. Šira procjena zahtijevala bi više generacija, različite početne vrijednosti generatora i zasebne eksperimente s drugim stopama učenja, duljinama sekvence i veličinama efektivne serije.

5.9. Usporedba rezultata s povezanim istraživanjima

Rezultati ovog rada mogu se smjestiti u kontekst prethodnih istraživanja generativne umjetne inteligencije u kreativnom pisanju, uz važnu ogradu da se razlikuju korišteni modeli, jezici, zadaci i postupci evaluacije. Zbog toga cilj usporedbe nije izravno izjednačiti numeričke rezultate, nego utvrditi podudaraju li se uočeni obrasci s nalazima srodnih istraživanja.

Marco, Rello i Gonzalo [10] pokazali su da u kratkom kreativnom pisanju sama veličina modela nije presudna te da manji modeli prilagođeni konkretnom zadatku mogu ostvariti konkurentne rezultate u odnosu na veće modele i ljudske autore. Rezultati ovog rada upućuju na srodan obrazac na hrvatskom jeziku: prilagodba postojećeg YugoGPT modela specijaliziranom književnom korpusu bila je povezana s boljim rezultatima od baznog modela u većini primijenjenih postupaka evaluacije. Ipak, ovdje se ne uspoređuje YugoGPT s ljudskim autorima ni s drugim arhitekturama, pa se zaključak ograničava na učinak prilagodbe unutar istog modela.

S književne strane, Shanahan i Clarke [9] naglašavaju da procjena kreativnosti velikih jezičnih modela zahtijeva više od jedne automatske mjere te da su za književni tekst važni elementi poput stila, koherentnosti i odnosa prema početnoj uputi. Takvo je polazište blisko evaluacijskom postupku ovog rada, u kojem perpleksitet i pokazatelji temeljeni na pravilima nisu korišteni kao jedini kriterij, nego su dopunjeni kvalitativnom analizom, procjenama pomoću modela umjetne inteligencije i korisničkom studijom. Razlike između pojedinih pokazatelja u ovom istraživanju dodatno potvrđuju opravdanost takvog višestrukog pristupa: poboljšanje nakon finog podešavanja bilo je izraženije u književnom dojmu i zanimljivosti nego u jezičnoj ispravnosti i jednostavnim leksičkim pokazateljima.

Rezultati se mogu promatrati i u odnosu na istraživanje Niloya i suradnika [8], u kojem uporaba ChatGPT-a kod studenata nije dovela do poboljšanja svih sastavnica kreativnog pisanja. Iako je riječ o drukčijem istraživačkom pitanju jer se ondje procjenjuje utjecaj alata na ljudsko pisanje, a ovdje kvaliteta teksta koji generira prilagođeni model, oba rada pokazuju da učinak generativne umjetne inteligencije nije jednoznačan i da ovisi o promatranom kriteriju. U ovom radu fino podešavanje također nije jednako poboljšalo sva svojstva teksta, što je posebno vidljivo u maloj razlici jezične ispravnosti i pojedinim kvalitativno slabijim generacijama.

Posebnost provedenog istraživanja u odnosu na navedene radove jest usmjerenost na hrvatski jezik te prilagodba višejezičnog modela kuriranom korpusu hrvatske književne proze. Dobiveni rezultati stoga dopunjuju postojeća istraživanja primjerom jezika s manje

dostupnih resursa i pokazuju da QLoRA prilagodba može poboljšati kvalitetu generiranih književnih nastavaka i bez promjene osnovne arhitekture modela. Zbog ograničenog broja promptova, jedne generacije po modelu i jedne odabrane konfiguracije, taj nalaz treba tumačiti kao rezultat provedenog eksperimenta, a ne kao opću tvrdnju o svim modelima ili oblicima kreativnog pisanja.

6. Zaključak

Cilj rada bio je ispitati može li se predtrenirani model YugoGPT prilagoditi kreativnom pisanju na hrvatskom jeziku. Model je fino podešen QLoRA metodom na književnom korpusu različitih autora, razdoblja i stilova tijekom deset epoha, uz praćenje gubitka i perpleksiteta na izdvojenom validacijskom skupu.

QLoRA fino podešavanje smanjilo je perpleksitet s 12,06 za bazni model na 10,55 za odabranu kontrolnu točku nakon sedme epohe. Najveći dio poboljšanja ostvaren je u prvih pet epoha, nakon čega su se vrijednosti stabilizirale, a kasnije epohe nisu pokazale dosljedno kvalitativno poboljšanje. Analiza temeljena na pravilima nije pokazala izraženu promjenu gustoće vokabulara ni prosječne duljine rečenica.

Na šest odabranih promptova i uz jednu generaciju po modelu evaluacija pomoću modela umjetne inteligencije pokazala je poboljšanje smislenosti, stilskog podudaranja i zanimljivosti, dok je razlika u jezičnoj ispravnosti bila mala. U korisničkoj studiji na 61 potpuno ispunjenom zapisu fino podešeni model ostvario je ukupni prosjek 3,71, naspram 2,86 za bazni model, te je odabran kao bolji u 80,1 % usporedbi. Književni stil pritom uključuje subjektivno percipiranu originalnost, opisnost i atmosferu.

Kvalitativna analiza pokazala je da fino podešeni model češće zadržava temu, razvija početni motiv i oblikuje književnu atmosferu. Ipak, poboljšanje nije bilo potpuno dosljedno: u šestom promptu bazni je model zadržao uvjerljiviji pripovjedni oblik, dok je fino podešeni odgovor prešao u sažetak.

Glavna ograničenja modela ostaju gramatičke i pravopisne nepravilnosti, pogrešno oblikovane riječi i povremeni nelogični prijelazi. Istraživanje je ograničeno na šest promptova, jednu generaciju po modelu za svaki prompt, jednu početnu vrijednost generatora i jednu osnovnu konfiguraciju hiperparametara. Validacijski skup namjerno je oblikovan od triju cjelovitih pripovijetki istog autora kako bi se pratila prilagodba ciljnom književnom stilu, pa se vrijednosti perpleksiteta tumače unutar toga stilski homogenog skupa. Evaluacija pomoću modela umjetne inteligencije zato se tumači kao dopuna, a ne zamjena za ljudsku procjenu.

Usporedba s povezanim istraživanjima pokazuje da se dobiveni nalazi uklapaju u širi obrazac prema kojem prilagodba modela konkretnom zadatku može imati važnu ulogu u kreativnom generiranju, dok sama veličina modela nije jedini pokazatelj uspješnosti [10]. Istodobno, u skladu s književno usmjerenim pristupima evaluaciji [9], rezultati potvrđuju potrebu za kombiniranjem više vrsta procjene jer poboljšanje nije bilo jednako izraženo u

svim svojstvima teksta. Doprinos ovog rada pritom je primjena takvog pristupa na hrvatski jezik i kurirani korpus hrvatske književne proze.

Rezultati provedenog eksperimenta pokazuju da je na šest odabranih promptova i uz jednu generaciju po modelu QLoRA prilagodba YugoGPT-a bila povezana s nižim perpleksitetom te višim korisničkim procjenama. Zbog malog broja promptova, jednoga uzorkovanja po promptu i namjerno uskog validacijskog skupa rezultate nije moguće generalizirati na sve vrste hrvatske književne proze. Buduća istraživanja trebala bi uključiti više promptova, ponovljene generacije i usporedbu dodatnih konfiguracija treniranja.

Popis literature

- [1] M. A. Runco i G. J. Jaeger, „The Standard Definition of Creativity“, *Creativity Research Journal*, sv. 24, izd. 1, str. 92–96, 2012, doi: 10.1080/10400419.2012.650092. [Na internetu]. Dostupno na: <https://doi.org/10.1080/10400419.2012.650092> [Pristupljeno: 26-srp-2026].
- [2] M. Sharples, „Automated Essay Writing: An AIED Opinion“, *International Journal of Artificial Intelligence in Education*, sv. 32, izd. 4, str. 1119–1126, 2022, doi: 10.1007/s40593-022-00300-7. [Na internetu]. Dostupno na: <https://doi.org/10.1007/s40593-022-00300-7> [Pristupljeno: 26-srp-2026].
- [3] J. Tsao i C. Nogues, „Beyond the author: Artificial intelligence, creative writing and intellectual emancipation“, *Poetics*, sv. 102, čl. 101865, 2024, doi: 10.1016/j.poetic.2024.101865. [Na internetu]. Dostupno na: <https://doi.org/10.1016/j.poetic.2024.101865> [Pristupljeno: 26-srp-2026].
- [4] P. Alexopoulos, M. Kladaki i K. Mastrothanas, „Enhancing creative writing skills through Large Language Models: A systematic literature review“, u *Γλώσσα, Εκπαίδευση και Τεχνητή Νοημοσύνη*, Sveučilište na Kreti, 2025, str. 359–374. [Na internetu]. Dostupno na: https://school.edc.uoc.gr/el/content_page/download_file/103 [Pristupljeno: 26-srp-2026].
- [5] A. Guo, S. Sathyanarayanan, L. Wang, J. Heer i A. X. Zhang, „From Pen to Prompt: How Creative Writers Integrate AI into their Writing Practice“, u *Proceedings of the 2025 Conference on Creativity and Cognition*, New York, NY, SAD: Association for Computing Machinery, 2025, str. 527–545, doi: 10.1145/3698061.3726910. [Na internetu]. Dostupno na: <https://doi.org/10.1145/3698061.3726910> [Pristupljeno: 26-srp-2026].
- [6] Z. Li, C. Liang, J. Peng i M. Yin, „The Value, Benefits, and Concerns of Generative AI-Powered Assistance in Writing“, u *Proceedings of the 2024 CHI Conference on Human Factors in Computing Systems*, New York, NY, SAD: Association for Computing Machinery, 2024, čl. 1048, str. 1–25, doi: 10.1145/3613904.3642625. [Na internetu]. Dostupno na: <https://doi.org/10.1145/3613904.3642625> [Pristupljeno: 26-srp-2026].
- [7] L. Svoboda i S. Beliga, „Evaluation of Croatian Word Embeddings“, u *Proceedings of the Eleventh International Conference on Language Resources and Evaluation (LREC 2018)*, Miyazaki, Japan: European Language Resources Association, 2018. [Na internetu]. Dostupno na: <https://aclanthology.org/L18-1240/> [Pristupljeno: 26-srp-2026].
- [8] A. C. Niloy, S. Akter, N. Sultana, J. Sultana i S. I. U. Rahman, „Is ChatGPT a menace for creative writing ability? An experiment“, *Journal of Computer Assisted Learning*, sv. 40, izd. 2, str. 919–930, 2024, doi: 10.1111/jcal.12929. [Na internetu]. Dostupno na: <https://doi.org/10.1111/jcal.12929> [Pristupljeno: 26-srp-2026].
- [9] M. Shanahan i C. Clarke, „Evaluating Large Language Model Creativity from a Literary Perspective“, arXiv:2312.03746, 2023, doi: 10.48550/arXiv.2312.03746. [Na internetu]. Dostupno na: <https://arxiv.org/abs/2312.03746> [Pristupljeno: 26-srp-2026].
- [10] G. Marco, L. Rello i J. Gonzalo, „Small Language Models can Outperform Humans in Short Creative Writing: A Study Comparing SLMs with Humans and LLMs“, u *Proceedings of the 31st International Conference on Computational Linguistics*, Abu Dhabi, UAE: Association for Computational Linguistics, 2025, str. 6552–6570. [Na internetu]. Dostupno na: <https://aclanthology.org/2025.coling-main.437/> [Pristupljeno: 26-srp-2026].

- [11] A. Fan, M. Lewis i Y. Dauphin, „Hierarchical Neural Story Generation“, u Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), Melbourne, Australija: Association for Computational Linguistics, 2018, str. 889–898, doi: 10.18653/v1/P18-1082. [Na internetu]. Dostupno na: <https://aclanthology.org/P18-1082/> [Pristupljeno: 26-srp-2026].
- [12] X. Peng, K. Xie, A. Alabdulkarim, H. Kayam, S. Dani i M. O. Riedl, „Guiding Neural Story Generation with Reader Models“, u Findings of the Association for Computational Linguistics: EMNLP 2022, Abu Dhabi, UAE: Association for Computational Linguistics, 2022, str. 7087–7111, doi: 10.18653/v1/2022.findings-emnlp.526. [Na internetu]. Dostupno na: <https://aclanthology.org/2022.findings-emnlp.526/> [Pristupljeno: 26-srp-2026].
- [13] D. Jurafsky i J. H. Martin, Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition with Language Models, 3. izd., mrežni rukopis, 2026. [Na internetu]. Dostupno na: <https://web.stanford.edu/~jurafsky/slp3/> [Pristupljeno: 26-srp-2026].
- [14] A. Vaswani i sur., „Attention Is All You Need“, u Advances in Neural Information Processing Systems 30, 2017, str. 5998–6008. [Na internetu]. Dostupno na: <https://papers.nips.cc/paper/7181-attention-is-all-you-need> [Pristupljeno: 26-srp-2026].
- [15] A. Q. Jiang i sur., „Mistral 7B“, arXiv:2310.06825, 2023, doi: 10.48550/arXiv.2310.06825. [Na internetu]. Dostupno na: <https://arxiv.org/abs/2310.06825> [Pristupljeno: 26-srp-2026].
- [16] A. Gordić, „YugoGPT“, repozitorij modela gordicaleksa/YugoGPT, Hugging Face, bazni model od 7 milijardi parametara temeljen na arhitekturi Mistral 7B, 2024. [Na internetu]. Dostupno na: <https://huggingface.co/gordicaleksa/YugoGPT> [Pristupljeno: 27-srp-2026].
- [17] E. J. Hu i sur., „LoRA: Low-Rank Adaptation of Large Language Models“, u International Conference on Learning Representations, 2022. [Na internetu]. Dostupno na: <https://openreview.net/forum?id=nZeVKeeFYf9> [Pristupljeno: 26-srp-2026].
- [18] T. Dettmers, A. Pagnoni, A. Holtzman i L. Zettlemoyer, „QLoRA: Efficient Finetuning of Quantized LLMs“, u Advances in Neural Information Processing Systems 36, 2023, str. 10088–10115. [Na internetu]. Dostupno na: https://proceedings.neurips.cc/paper_files/paper/2023/hash/1feb87871436031bdc0f2beaa62a049b-Abstract-Conference.html [Pristupljeno: 26-srp-2026].
- [19] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger i Y. Artzi, „BERTScore: Evaluating Text Generation with BERT“, u International Conference on Learning Representations, 2020. [Na internetu]. Dostupno na: <https://openreview.net/forum?id=SkeHuCVFDr> [Pristupljeno: 26-srp-2026].
- [20] L. Ouyang i sur., „Training language models to follow instructions with human feedback“, u Advances in Neural Information Processing Systems 35, 2022, str. 27730–27744. [Na internetu]. Dostupno na: https://proceedings.neurips.cc/paper_files/paper/2022/hash/b1efde53be364a73914f58805a001731-Abstract-Conference.html [Pristupljeno: 26-srp-2026].
- [21] L. Zheng i sur., „Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena“, u Advances in Neural Information Processing Systems 36, 2023, str. 46595–46623. [Na internetu]. Dostupno na: https://proceedings.neurips.cc/paper_files/paper/2023/hash/91f18a1287b398d378ef22505bf41832-Abstract-Datasets_and_Benchmarks.html [Pristupljeno: 26-srp-2026].

- [22] Wikimedia Foundation, „Wikizvor“ (bez dat.) [Na internetu]. Dostupno na: <https://hr.wikisource.org/> [Pristupljeno: 26-srp-2026].
- [23] Hrvatski sabor, „Zakon o autorskom pravu i srodnim pravima“, Narodne novine, br. 111/2021. [Na internetu]. Dostupno na: https://narodne-novine.nn.hr/clanci/sluzbeni/2021_10_111_1941.html [Pristupljeno: 26-srp-2026].
- [24] Leksikografski zavod Miroslav Krleža, Hrvatska enciklopedija, mrežno izdanje (bez dat.) [Na internetu]. Dostupno na: <https://www.enciklopedija.hr/> [Pristupljeno: 26-srp-2026].
- [25] Google LLC, Gemini, model Gemini 3 Flash, 2025. [Generativni sustav umjetne inteligencije, mrežna aplikacija]. Dostupno na: <https://gemini.google.com/> [Pristupljeno: 26-srp-2026].
- [26] A. Paszke i sur., „PyTorch: An Imperative Style, High-Performance Deep Learning Library“, u Advances in Neural Information Processing Systems 32, 2019, str. 8024–8035. [Na internetu]. Dostupno na: <https://papers.nips.cc/paper/9015-pytorch-an-imperative-style-high-performance-deep-learning-library> [Pristupljeno: 26-srp-2026].
- [27] T. Wolf i sur., „Transformers: State-of-the-Art Natural Language Processing“, u Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, Association for Computational Linguistics, 2020, str. 38–45, doi: 10.18653/v1/2020.emnlp-demos.6. [Na internetu]. Dostupno na: <https://aclanthology.org/2020.emnlp-demos.6/> [Pristupljeno: 26-srp-2026].
- [28] S. Sinclair i G. Rockwell, Voyant Tools, mrežna inačica dostupna 2026. [Mrežna aplikacija]. Dostupno na: <https://voyant-tools.org/> [Pristupljeno: 26-srp-2026].
- [29] Google LLC, Google Forms (bez dat.) [Mrežna aplikacija]. Dostupno na: <https://workspace.google.com/products/forms/> [Pristupljeno: 26-srp-2026].
- [30] OpenAI, ChatGPT, model GPT-5.5 Instant, 2026. [Generativni sustav umjetne inteligencije, mrežna aplikacija]. Dostupno na: <https://chatgpt.com/> [Pristupljeno: 26-srp-2026].
- [31] Microsoft Corporation, Microsoft Excel for Microsoft 365, Current Channel, 2026. [Softverska aplikacija]. Dostupno na: <https://www.microsoft.com/microsoft-365/excel> [Pristupljeno: 27-srp-2026].
- [32] I. Goodfellow, Y. Bengio i A. Courville, Deep Learning. Cambridge, MA, SAD: MIT Press, 2016, pogl. 8. [Na internetu]. Dostupno na: <https://www.deeplearningbook.org/> [Pristupljeno: 26-srp-2026].

Popis slika

Slika 1: Kretanje vrijednosti funkcije gubitka tijekom treniranja.	23
Slika 2: Perpleksitet baznog modela i spremljenih kontrolnih točaka po epohama.	25
Slika 3: Oblak riječi baznog modela YugoGPT.	26
Slika 4: Oblak riječi fino podešenog modela nakon sedme epohe.	27
Slika 5: Struktura ispitanika prema dobi.	34
Slika 6: Struktura ispitanika prema spolu.	34
Slika 7: Učestalost korištenja alata umjetne inteligencije među ispitanicima.	35

Popis tablica

Tablica 1: Struktura objedinjenog heterogenog književnog korpusa.	9
Tablica 2: Provjera autorskopравnog statusa autora uključenih u korpus.	10
Tablica 3: Preliminarni promptovi korišteni pri kvalitativnom odabiru kontrolne točke.	19
Tablica 4: Promptovi korišteni u završnoj evaluaciji baznog i fino podešenog modela.	19
Tablica 5: Statistički pokazatelji dobiveni analizom u alatu Voyant Tools.	27
Tablica 6: Rezultati procjene smislenosti i koherentnosti.	28
Tablica 7: Rezultati procjene stilskog podudaranja.	29
Tablica 8: Rezultati procjene jezične ispravnosti.	30
Tablica 9: Rezultati procjene zanimljivosti.	31
Tablica 10: Rezultati korisničkih ocjena prema kriterijima.	35
Tablica 11: Ocjene i izravne preferencije prema promptovima.	36
Tablica 12: Sažetak usporedbe baznog i fino podešenog modela.	37
Tablica 13: Konfiguracija modela i QLoRA prilagodbe.	55
Tablica 14: Konfiguracija podataka, okruženja i treniranja.	55
Tablica 15: Kontrolne točke i perpleksitet.	56
Tablica 16: Parametri generiranja.	56
Tablica 17: Djela u skupu za treniranje.	57
Tablica 18: Djela u izdvojenom validacijskom skupu.	57
Tablica 19: Mrežni izvori Hrvatske enciklopedije za podatke o autorima.	58

Prilozi

Prilozi sadržavaju cjelovite nastavke korištene u završnoj evaluaciji, sažetak konfiguracije eksperimenta, pojedinačne mrežne izvore djela uključenih u korpus te preliminarne promptove i nastavke korištene pri odabiru kontrolne točke.

Prilog 1: Primjeri generiranih tekstova

U nastavku su preneseni promptovi i generirani nastavci korišteni u evaluaciji. Tekstovi su navedeni bez naknadnih jezičnih ispravaka. Nagli završeci posljedica su ograničenja generiranja na najviše 300 novih tokena.

Prompt 1

Početni tekst: Jednom davno, u dalekoj zemlji, živio je kralj poznat po svojoj mudrosti i pravednosti. Jednoga jutra pred vrata njegove palače stigao je nepoznati putnik.

Nastavak baznog modela YugoGPT

Kralj mu reče da može ući, a on mu odgovori: "Želim samo jedan gutljaj vode iz vašega zdenca." Kralj naredi slugama da dovedu vodonošu i napune posudu vodom iz zdenca broj pregleda - 23510.04.2011 BIH, Zenica Foto: Hazim Čukle Jednom davano, u daljoj zeni, ivi o kralj jp znato po svoj m udrsosti i pravdnsoti. Jednog jutara pred vrta nje pala e stigo nepozna t putnik...

Nastavak fino podešenog modela YugoGPT

Kralj mu reče da može ući, a on mu odgovori:

- Dajte mi za hranu i prenoćište, pa ću vam ispričati priču.

Kralju se priča učini zanimljiva, pa reče:

- Pričaj, pripovjedaču!

Putnik odgovorio: - Dok sam bio mlad, želio sam steći što više znanja o svijetu. Tako sam odlučio posjetiti čarobnog gusara. On me je primio u svoj brod i otplovili smo na more. Plovili bismo tako dugo dok nismo naišli na kraj svijeta. Brodom smo došli do jedne ogromne planine. Uspinjali smo se danima, sve dok ne dođemo do jednih vrata. Kad ih otvorih, ugledah veliku dvoranu. Sjedio je tu čaroba gusar sa starim čarobjikom, a oko njih mnoštvo ljudi, žena i djece. Ja im priđoh, a čarobjuk mi reče

Prompt 2

Početni tekst: Bijaše kasna jesen. Magla se polako spuštala nad dolinom, a stara kamena kuća stajala je sama na rubu šume. Nitko već godinama nije ulazio u nju, sve dok se jedne večeri iza prozora nije pojavilo slabo svjetlo.

Nastavak baznog modela YugoGPT

Kada su mještani vidjeli da netko živi u toj kuci, odlučili su poslati delegaciju koja će ga pozvati natrag u selo. Sutradan, stariji čovjek sjedio je pred vratima i čekao. Bio je tog dana odjeven u crno i imao je brkove poput orla. Vrijeme je prolazilo, a nitko nije dolazio. Nakon nekoliko sati ogladnio je pa je odluci odvojiti nešto hrane sa strane. U tom trenutku iznenada začuo se topot konja i pjesma. Bila je to delegacija. "Dobar dan, zar Vi tu živite?" - upitao je prvi čovjek. "Da." - odgovori on. "Onda biste li nam rado mogli pridružiti?" - dodao je drugi. "Naravno." - reče on i otisnu se putem.

Jednom davno, u nekom malom gradu, živio je jedan siromašni obrtnik. Imao je jednog sina i želio mu je priuštiti najbolje obrazovanje. No,

Nastavak fino podešenog modela YugoGPT

Kroz maglu se naziralo ljudsko obličje koje je kao duh lutalo sobama. Pogled je bila zagledan u tamnu noć i guste oblake iznad nje, a ruke su mu bile skrštene preko prsa, pa je tako čvrsto držao glavu da su mu se usnice stisle kao kod onoga tko nešto želi jako reći, ali ne može progovoriti.

Potom se okrenuo i pogledao u ogromno ogledalo. Na njemu se vidjelo njegovo tužno lice, ozbiljno, staro, umorno, a ispod bijele brade titrao je dugačak brk. Sve to odavalo je da je riječ o starcu kojemu se bliži kraj.

- Čovjek - pomislio je - treba biti jak da bi mogao podnijeti svoju starost. I toliko sam se trudio, radio... A vidi sad! Zar je sve uzalud? Uvijek sam govorio da je za starca najbolje da ga pokopaju u njivi. Tamo ć

Prompt 3

Početni tekst: Prije izlaska sunca stari ribar i njegov unuk polako su gurali barku prema mirnom moru. Djed se nasmiješio i rekao:

Nastavak baznog modela YugoGPT

– Kad bi sve bilo tako jednostavno kao što je ovo, život bi bio lijep.

Kako su se približavali pučini, djed ugleda nekog čudnog čovjeka na brodu u daljini. Bio je to čovjek kojem se činilo da sve zna, a zapravo ništa nije razumio. Dok mu je prilazio, čuo je kako kaže svom prijatelju: – Znate, želim vam reći kako je život tako kompliciran. Ne bih vas htio plašiti, ali postoji više od 50 miliona vrsta, 278 vrsta kišnih glista, 16 vrsta morskih ježeva...

Unuk ga je blijedo pogledao i upitao:

– Ti si lud! To su samo vrste riba koje smo ulovili tijekom godina.

Nastavak fino podešenog modela YugoGPT

„Vidjet ćemo tko je danas sretniji, morski konjic ili mi!”

Kad su došli na pučinu, djed je podigao mrežu. Voda se počela zamućivati, a onda je zablistala cijela kristalna posuda puna srebrnih ribica.

Morski je konjac plivao okolo i čudno se smijuljio. Tada se zavitlao u more i nestao u dubini.

Djed je uzbuđeno reka da će uloviti još više, ali ovaj put mreže ne bijaše ni od jedne vlasi. Uхватili su samo komadić starog drva, koji se našao na površini mora.

- Ne, ne, danas je sretan morskii konj! - zaključi djed.

Nakon što su stigli na obalu, djeda je zaustavio nepoznati čovjek. Rekao mu je da ga je pratio od trenutka kad je dignuo mrežen iz vode i pitao ga što je toliko sretnog

Prompt 4

Početni tekst: Mladić je u staroj knjižnici pronašao požutjelo pismo skriveno između dviju knjiga. Kada ga je otvorio i pročitao prvu rečenicu, učinilo mu se da se cijela prostorija promijenila.

Nastavak baznog modela YugoGPT

Kao da su sve knjige oko njega postale žive, a neke od njih pokušavaju mu se obratiti. Mladić otkrije da je riječ o neobičnom svijetu koji ima svoja pravila i zakone.

Komentari

Nastavak fino podešenog modela YugoGPT

Osjetio je neobičan miris, a zidovi kao da su postali mekani. Morao je sjesti na pod jer mu se vrtjelo u glavi. Ubrzo se sve vratilo u normalu, ali on nije mogao zaboraviti što je pročitano.

Saznao je da je njegov djed bio u ljubavnoj vezi sa ženom koja je bila udana za jednog grofa. Ona je očajnički željela pobjeći od supruga, a i imala je dijete s grofom pa joj je djed obećavao da će se pobrinuti za nju. Djevojka se zvala Anica i nakon nekoliko mjeseci traganja i dogovaranja napokon su se sastali u jednom malom mjestu blizu Zagreba. Bili su sami, nitko ih nije vidio. Dogovarali su se gdje bi se mogli sresti, no ona je uvijek tražila da bude negdje drugdje. Naposljetku je predložila djedu da se nađu u knji

Prompt 5

Početni tekst: Bura je cijelu noć udarala o prozore, a nitko u selu nije slutio što će jutro donijeti. Kada su se prvi stanovnici probudili, na glavnom se trgu nalazio nepoznati predmet.

Nastavak baznog modela YugoGPT

Bilo je to svemirsko vozilo koje su mališani izvukli iz garaže i poslali u svemire. Ubrzo su ga pronašla dva čudnovata bića, jedan od njih bio je znanstvenik, a drugi njegov pomoćnik, koji su se odlučili istražiti okolicu. No kako ih nitko nije razumio, tako su se izgubili u potrazi za spasom. U međuvremenu, neki stanovnik sela pokušao im je prići i vidjeti što se dogodilo s ljupkim vanzemalcima, ali oni mu se nisu htjeli približiti zbog velike bure. Ipak, znajući da su dobri, srdačno su ih pozvali da dođu kod njih u svoju kućicu, po mogućnosti da ih malo utople. Kada su ušli u kućicu i ugledali vatru na ognjištu, pomislili su da su na pravome putu. Ubrzo nakon ulaska u kuh

Nastavak fino podešenog modela YugoGPT

Bilo ga je vrlo teško opisati, jer je bio sastavljen od različitih dijelova. S jedne strane izgledao je kao velika crna gusjenica, s druge kao zmaj, a po sredini je imao ljudsko tijelo.

Sve oko toga čudnog bića bila je gužva i vika. Iako su mu svi prilazili mirno i tiho, on ih je zastrašujućim glasom potjerivao natrag.

– Tko ste? – pitali su ga ljudi znatiželjno.

Čudovište je samo šutjelo. Uхватило se za kameni stup, pa se, mašući rukama, okretalo prema svakome tko bi mu prišao.

Zatočniku iz groba nije bilo drago što ga vide. Odmah je znao da su to ljude njegova sela koje je dugo vremena sanjao, ali i oni su bili došli iz drugog svijeta i vidjeli da se radi o nečem strašnom. Njihovu

Prompt 6

Početni tekst: U malom primorskom mjestu svi su vjerovali da stari svjetionik krije tajnu. Jedne olujne noći dogodilo se nešto što je promijenilo živote svih stanovnika.

Nastavak baznog modela YugoGPT

Kada su dvoje djece pobjegla od oluje u kulu svjetioničara, sve se promijeni...

Prolazim pokraj starog svjetlonika i ugledam nekoga kako sjedi na njegovoj kamenoj klupi. Nije mi jasno kako nisam vidio tog čovjeka dok sam prolazio pokraj svjetonika prije sat vremena. Stigao sam do vrata, ali ih ne otvaram jer znam da će me unutra čekati netko kome je potreban razgovor. Ne želim sad ulaziti u razgovore.

Pozdravljam ga: „Dobar dan, gospodine“, a on kaže: „Poznat si mi, a opet, prvi put te vidim“. Znam da je to izraz ljubaznosti, ali ja ne volim takva pitanja. Lakše mi je kad ljudi znaju sve o meni. Ipak mu odgovorim: „Vjerojatno smo se sreli negdje u gradu“. Sjednem pokraj njega. Odmah me upita: „Znaš li ti zašto sam tu

Nastavak fino podešenog modela YugoGPT

Kada su djeca doznala istinu, njihova znatiželja i prijateljstvo pomoći će im da otkriju još jedan veliki i opasni tajanstveni događaj...

Ova zanimljiva priča o tajnama, obiteljskim odnosima, prijateljstvu i hrabrosti ispunjena je avanturističkim elementima te poticajna za mlade čitatelje da samostalno izraze svoje mišljenje i donesu zaključke.

Poveznice na razgovore korištene u evaluaciji pomoću modela umjetne inteligencije

U nastavku su navedene javno podijeljene povijesti razgovora za četiri procjene opisane u poglavlju 5.4.

- [5.4.1. Procjena smislenosti i koherentnosti](#)
- [5.4.2. Procjena stilskog podudaranja](#)
- [5.4.3. Procjena jezične ispravnosti](#)
- [5.4.4. Procjena zanimljivosti](#)

Prilog 2: Konfiguracije modela i hiperparametara

Konfiguracija je preuzeta iz završne inačice Jupyter bilježnice korištene u Google Colabu. Treniranje je provedeno tijekom deset epoha, uz spremanje kontrolne točke nakon svake epohe.

Tablica 13: Konfiguracija modela i QLoRA prilagodbe.

Stavka	Vrijednost
Bazni model	gordicaleksa/YugoGPT
Arhitektura baznog modela	Mistral 7B, dekoderski autoregresivni model
Način učitavanja baznog modela	4-bitna kvantizacija
Tip 4-bitne kvantizacije	NF4
Dvostruka kvantizacija	uključena
Metoda finog podešavanja	QLoRA
LoRA rang (r)	8
LoRA faktor skaliranja (lora_alpha)	16
LoRA dropout	0,05
Ciljni moduli	q_proj i v_proj
Pri stranost LoRA slojeva	bez dodatne pristranosti (bias = none)
Vrsta zadatka	autoregresivno jezično modeliranje (CAUSAL_LM)
Ukupan broj parametara	7.245.139.968
Broj trenirajućih parametara	3.407.872

Tablica 14: Konfiguracija podataka, okruženja i treniranja.

Stavka	Vrijednost
Datoteke korpusa	train.txt i validation.txt
Broj književnih djela u skupu za treniranje	35
Broj književnih djela u izdvojenom validacijskom skupu	3
Broj tekstualnih sekcija u skupu za treniranje	149
Broj tekstualnih sekcija u izdvojenom validacijskom skupu	15
Broj tokeniziranih blokova u skupu za treniranje	3.393
Broj tokeniziranih blokova u izdvojenom validacijskom skupu	349
Duljina sekvence	256 tokena
Najmanja duljina zadržanog odsječka	32 tokena
Broj epoha	10
Veličina serije po uređaju	1
Akumulacija gradijenata	8 koraka
Efektivna veličina serije	8
Stopa učenja	5×10^{-5}
Warmup omjer	0,05
Weight decay	0,01
Optimizator	paged_adamw_8bit
Gradijentno checkpointiranje	uključeno
Preciznost na NVIDIA T4	FP16
Početna vrijednost generatora slučajnih brojeva	42
Evaluacija i spremanje	nakon svake epohe
Inačica Pythona	3.12
Inačica biblioteke PyTorch	2.11.0+cu128
Inačica biblioteke Transformers	5.14.1
Inačica biblioteke PEFT	0.19.1
Inačica biblioteke Accelerate	1.14.0

Stavka	Vrijednost
Inačica biblioteke bitsandbytes	0.50.0
Grafički procesor	NVIDIA Tesla T4, 16 GB grafičke memorije
Približno trajanje treniranja	72 sata

Tablica 15: Kontrolne točke i perpleksitet.

Model / epoha	Korak kontrolne točke	Perpleksitet
Bazni model	—	12,06
Epoha 1	424	11,69
Epoha 2	848	11,05
Epoha 3	1272	10,73
Epoha 4	1696	10,62
Epoha 5	2120	10,57
Epoha 6	2544	10,55
Epoha 7	2968	10,55
Epoha 8	3392	10,55
Epoha 9	3816	10,53
Epoha 10	4240	10,57

Tablica 16: Parametri generiranja.

Stavka	Vrijednost
Najveći broj novih tokena	300
Uzorkovanje	uključeno (do_sample = True)
Temperatura	0,7
Top-p	0,9
Top-k	40
Penalizacija ponavljanja	1,1
Zabrana ponavljanja n-grama	3 tokena
Početna vrijednost generatora slučajnih brojeva	42

Za završnu evaluaciju odabrana je kontrolna točka nakon sedme epohe, odnosno checkpoint-2968. Google Gemini 3 Flash korišten je unutar okruženja Google Colab pri razvoju i prilagodbi dijelova koda. U korištenom sučelju nije bila dostupna zasebna pohranjena povijest tih razgovora.

Prilog 3: Djela i mrežni izvori korištenog korpusa

Tablice u ovom prilogu navode sva djela identificirana prema naslovnim oznakama u datotekama train.txt i validation.txt. Oznake Wikizvor u stupcu Izvor povezane su s pojedinačnim stranicama djela na hrvatskom Wikizvoru, koji je korišten kao primarni mrežni izvor digitalnih prijepisa. Na kraju priloga navedene su i pojedinačne natuknice Hrvatske enciklopedije korištene za provjeru godina smrti autora.

Tablica 17: Djela u skupu za treniranje.

Autor	Djelo	Izvor
Antun Gustav Matoš	Cvijet sa raskršća	Wikizvor
Antun Gustav Matoš	Camao	Wikizvor
Antun Gustav Matoš	Miš	Wikizvor
Antun Gustav Matoš	Balkon	Wikizvor
Antun Gustav Matoš	Moć savjesti	Wikizvor
Antun Gustav Matoš	Kip domovine leta 188*	Wikizvor
Antun Gustav Matoš	O tebi i o meni	Wikizvor
Antun Gustav Matoš	Lijepa Jelena	Wikizvor
Antun Gustav Matoš	Samotna noć	Wikizvor
Antun Gustav Matoš	Jesenska idila	Wikizvor
Ksaver Šandor Gjalski	Plemenitaši i plemići	Wikizvor
Ksaver Šandor Gjalski	Mlin kod ceste	Wikizvor
Ksaver Šandor Gjalski	Na Badnjak	Wikizvor
Ivana Brlić-Mažuranić	Šuma Striborova	Wikizvor
Ivana Brlić-Mažuranić	Regoč	Wikizvor
Ivana Brlić-Mažuranić	Sunce djever i Neva Nevičica	Wikizvor
Ivana Brlić-Mažuranić	Kako je Potjeh tražio istinu	Wikizvor
Ivana Brlić-Mažuranić	Ribar Palunko i njegova žena	Wikizvor
Ivana Brlić-Mažuranić	Bratac Jaglenac i sestrice Rutvica	Wikizvor
August Šenoa	Prijan Lovro	Wikizvor
August Šenoa	Prosjak Luka	Wikizvor
August Šenoa	Branka	Wikizvor
Vladimir Nazor	Anđeo u zvoniku	Wikizvor
Vladimir Nazor	Čovjek koji izgubi dugme	Wikizvor
Vladimir Nazor	Zmija	Wikizvor
Dinko Šimunović	Mrkodol	Wikizvor
Dinko Šimunović	Muljika	Wikizvor
Dinko Šimunović	Duga	Wikizvor
Dinko Šimunović	Alkar	Wikizvor
Dinko Šimunović	Đerdan	Wikizvor
August Cesarec	Tonkina jedina ljubav	Wikizvor
Janko Polić Kamov	Sloboda	Wikizvor
Janko Polić Kamov	Katastrofa	Wikizvor
Janko Polić Kamov	Žalost	Wikizvor
Janko Polić Kamov	Žena	Wikizvor

Tablica 18: Djela u izdvojenom validacijskom skupu.

Autor	Djelo	Izvor
Ksaver Šandor Gjalski	Perillustis ac generosus Cintek	Wikizvor
Ksaver Šandor Gjalski	Starci	Wikizvor
Ksaver Šandor Gjalski	Idila starog ljeta	Wikizvor

Mrežni izvori za provjeru podataka o autorima

Tablica 19: Mrežni izvori Hrvatske enciklopedije za podatke o autorima.

Autor	Mrežni izvor
Antun Gustav Matoš	Hrvatska enciklopedija
Ksaver Šandor Gjalski	Hrvatska enciklopedija
Ivana Brlić-Mažuranić	Hrvatska enciklopedija
August Šenoa	Hrvatska enciklopedija
Vladimir Nazor	Hrvatska enciklopedija
Dinko Šimunović	Hrvatska enciklopedija
August Cesarec	Hrvatska enciklopedija
Janko Polić Kamov	Hrvatska enciklopedija

Prilog 4: Preliminarni promptovi i generirani nastavci po epohama

U ovom prilogu navedeni su preliminarni promptovi i generirani nastavci epoha od 5 do 10 odnosno njihovih spremljenih kontrolnih točaka. Tekstovi su preneseni iz izlaza Jupyter bilježnice bez naknadnih jezičnih ispravaka. Preliminarni skup korišten je isključivo za kvalitativno razlikovanje kontrolnih točaka pri odabiru sedme epohe i nije korišten u završnoj evaluaciji baznog i fino podešenog modela.

Epoha 5 (checkpoint-2120)

Preliminarni prompt 1

Početni tekst: Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.

Generirani nastavak

Krenuo je prema šumi i odjednom začuo kako netko nešto pita. Bio je to njegov susjed Štef.

- Čujem da si došao iz Amerike! A što ima tamo? - upitao ga je.

- Nema ništa, osim onoga što čovjek sam sobom donese. Što imam ja? Zaradu. I sada će biti više posla nego prije, pa bi mogli obojica lijepo živjeti. Samo moramo raditi. Sve se može učiniti i postići, samo treba biti marljiv. Tako se snalaze svi ljudi koji su došli iz Ameriku. Pa zar nećeš i ti radije pošteno zarađivati nego krasti tuđe? - zapitao je Marko.

Štef mu odgovori:

- Ti si, brate, veliki čovik. Nego, reci mi, da li je istina da si ondje vidio morskog konja?

- To je, brale, glupost! Ali ako hoće, neka dođe k meni, da

Preliminarni prompt 2

Početni tekst: Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.

Generirani nastavak

Kad ga je uzela i stavila pod nos, čula je mali šapat: „Otvori vrata, otvori!“

Umjesto da se okrenula prema ulici, ona je otišla prema šumi. Bilo joj je drago što je mogla razgovarati sa svojim novim prijateljem. Šuma je bila puna ptica i leptira. Među stablima žuborile su potočići, a ispod grana skrivao se malen vrt pun cvijeća. Sve to je djevojačka duša zamišljala ljepšom od svih proljetnih snova. Uživala je u razgovoru s ključom. Na njegovu je zahtjevu odgovarala: „Vrata su zaključana.“ On bi tada ponovio: „Pokušaj opet, otključaj ih, otvorit će se.“

Kad bi ona pitala: „A gdje su ta vrata?“ on bi je upitao: „Ne poznaješ li ih? To su vrata tvoga srca.“

„Znam“, rekla bi

Preliminarni prompt 3

Početni tekst: Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.

Generirani nastavak

Pismo nije bilo dugačko:

Dragi brate! Na žalost moram ti priopćiti da je moja draga umrla jučer uvečer. Sahranjena je danas na groblju svetog Roka. Ako ćeš doći, pođi odmah. Tvoji sestrinci Janko i Vjekoslav.

Pismo je bilo potpisano crvenim slovima, a ispod potpisa stajala su dva mala križića. Gospoda Franje, koji je bio iznuren i prilično oslabio od neprestane brige za suprugu, ta vijest bila je kao grom iz vedrog neba. On se samo malo trgnuo, zatvorio oči i stavio pismo pred sebe, pa je šuteći ostao još pola sata sjediti, dok ga nije probudio dolazak sluškinje.

- Donesite mi odijelo, - reče on nesretnom čovjeku.

Iza ručka izdade naredbu da mu spremne kofer i da ga odnesu na stanicu. Nekol

Preliminarni prompt 4

Početni tekst: Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen. Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.

Generirani nastavak

Kad su ih ljudi vidjeli, bili su u strahu jer nisam ni na kakvoj stazi, već negdje u grmlju, a to se ne smije čuti.

Nekoliko dana poslije jelen se pojavio na cesti i onda su ga lovci ubili, a starica je od sreće zapjevala: „Ja sam bila u pravu.”

Poslije više nitko nije pričao o jelenu, ali ljude je nastavilo mučiti zvonjenje iz grma. Bilo je tako grozno i strašno da su seljaci mislili da je netko ukrao crkvena zvone i zakopao ih u zemlji.

Pitali su se gdje će biti sljedeće zvono, pa su uvijek neki od njih ostajali budni i u mraku čekali. Noćima bi se tresle kolibe, a psi lajali od straha, a ujutro bi se nalazile samo trave i lišća, ali nikada i zvonice.

Ljudi su govorili: „Tko zna š

Preliminarni prompt 5

Početni tekst: Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.

Generirani nastavak

Kad su počeli puštati plin, nitko nije ništa primijetio. Osim djevojke u crnom. Ona je stajala nasred perona i promatrala nešto na nebu.

Mladi su vojnici dobili zadatak da prikupe leševe. Uspjeli su ih sve pokupiti osim jednog.

Izašli su iz vlaka i vidjeli ga kako se diže prema oblacima.

- To nije moguće! - rekao je zapovjednik.

Izraz njegova lica nije odavao strah. Bio je to izraz razočaranja.

Nastavili su tražiti mrtve. Mladi je vojak odlučio pogledati još jedanput u smjeru oblaka. Tamo je stvarno bilo nešta što se podizalo. Nisu to bile ptice, već ljudska bića. Dva puta se uvjerio da je tako. Iznenadio se i pomislio: „Aha, vještice!”

No tada je shvatio da ono gore nisu vještice

Preliminarni prompt 6

Početni tekst: Uoči svadbe Ana je u majčinoj škrinji pronašla izblijedjelu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Generirani nastavak

Kada su se sreli, mladić joj reče da ga je ona čekala cijeloga života.

Epoha 6 (checkpoint-2544)

Preliminarni prompt 1

Početni tekst: Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.

Generirani nastavak

Krenuo je dalje i stigao do groblja. Tamo je vidio čovjeka kako sjedne uz njegova pokojnog oca, koji se okrene prema njemu, pa mu reče:

- Zar ne poznaješ me? Ja sam tvoj djed! - I onaj se okrenu od svoje sjenke i nestade. Marko ga više nije mogao vidjeti.

Preliminarni prompt 2

Početni tekst: Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.

Generirani nastavak

Kad ga je uzela i stavila pod nos, čula je mali šapat: „Otvori vrata, otvori vrta!”

Djevojka se okrenula prema gaju i pošla za šumskim putem. Nije znala kamo ide. A onda je pred njom iznikao divan dvorac s mnogo prozora, na prozorima su bile raznobojne zastave, a na krovu vijoreći crveni barjak. Dok je gledala taj prizor, čuo se velik prasak.

Najednom je vidjela da je nekoga udarilo drvo. Bijaše to lovac. Djevojku je oblio znoj od straha. Lovac je poginuo, ali je imao u rukama pušku. Dohvati je i zapuca u krošnje drveća. Između grana padnu tri ptice, jedna poslije druge. Bio je to lov na ptice. Djeca su plakala, a starci govorili: - Prokleta lovina! - i psovali lovca.

Kada je puška opalila treći

Preliminarni prompt 3

Početni tekst: Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.

Generirani nastavak

Pismo nije bilo dugačko:

Dragi brate! Na žalost moram ti priopćiti da je moja draga umrla jučer uvečer. Sahranjena je danas na groblju svetog Roka. Ako ćeš doći, pođi u gradsku vječnicu pa pitaj gdje je grob.

Dozvoljeno je posjetiti grobove. Tvoji Franjo i Lucija.

Kad je stavio papir u sanduk, opipnuo je džepove. U jednom su bile dvije dukate, a u drugom tri. Nato je izvadio svoj novac iz ogrtača i položio ga na stol. Onda je skinuo kaput i prsluk, pa ih objesio kraj vrata.

Povrh toga skinuo je čizme i zakopčao svoju košulju. Zatim je ponovo odjenuo prsluke i obuo se. Izvadio je iz džema štap i metnuo ga u ruksak. Zavezao je i čizmice. Podigao je pokrivač, namjestio ga

Preliminarni prompt 4

Početni tekst: Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen. Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.

Generirani nastavak

Kad su ih ljudi vidjeli, bili su u strahu jer nisam ni na kakvoj stazi, već negdje visoko u gorama.

Onda je u grad došla stara žena koja im je rekla da je to bijeli jelenski bog, a i on će se možda pojaviti. Ljudi su se smijali, ali kad je stiglo proljeće, stari su ljubavnici otišli u lov. Jedan od njih se vratio ranjen, a drugi je ostao među borima. Ondje ga je našao pastir te mu je donio hranu i vode. Sutradan je opet došao. No njega više nema! Pastir je pripovijedao da je mladić oti- šao sa jelenskim bogom.

Druga verzija:

Zaljubio se mlad čovjek u djevojku, no ona ga ne htjede. On se zato pretvorio u jelena.

Preliminarni prompt 5

Početni tekst: Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.

Generirani nastavak

Kad su napokon došli na red, bilo je krajnje vrijeme da se vlak pokrene. Vojnik je bio prvi. Uvukao je svoju torbu i počeo se penjati stubama. Trgovac je uhvatio za ruku, jer nije mogao tako brzo hodati. Žena u bijeloj bluzi izašla je iz ček-aone i stala uz rub kolosijeka. Na ogradu ju je naslonio mladić iz vlaka.

– Zbogom, dragi moji! – rekla je žena tiho i gledala ih ozbiljno, ali s nekom milinom. I zatim se okrenula od njih i stajala mirna na pustoj stanici. Vlak se sporo kretao, a ona je stajalo dugo, dok joj se lice nije izgubilo među stablima. Onda je nestala iz vidika. Samo se još

jednom zaustavila na malenom prozoru i mahala. Poslije toga je nastupila noć.

A kada je mjesec zašao, vlak je

Preliminarni prompt 6

Početni tekst: Uoči svadbe Ana je u majčinoj škrinji pronašla izbljedjelu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Generirani nastavak

Kada su se sreli, mladić joj reče da ga je ona čekala i prije 10 godina, a njegovu suprugu Ana nazva nepoželjnom strankom...

Epoha 7 (checkpoint-2968)

Preliminarni prompt 1

Početni tekst: Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.

Generirani nastavak

Krenuo je dalje do obližnjeg dvorca i ugledao kako gori crvena svjetiljka. Ušavši unutra, nađe u velikoj dvorani nekoliko staraca i jednu staricu, koji su pjevali i plesali oko stola. Na čelu svega sjedio je grof i njegov sin, a uz njih lijepa mlada žena.

- Tko ste? - upita Marka grof.

- Ja sam Marko, vaš kmet iz susjednog sela.

Grof ga prepozna i reče:

- Eto, vidite! Ovaj mladić je već 20 godina moj sluga, pa mu ništa ne fali. Svi smo mi u službi kod mene, pa tako i ja.

Marko shvati da je tu bila riječ o vampirima, te brzo odjaše natrag u svoje selo i zateče majku na samrti. On joj ispriča što je doživio, ali ona mu reče da će uskoro umrijeti i da 1e sva z

Preliminarni prompt 2

Početni tekst: Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.

Generirani nastavak

Kad ga je uzela i stavila pod nos, čula je mali šapat: „Otvori vrata, otvori vrta!”

Djevojka se okrenula prema gaju i pošla ravnom cestom kroz grmlje. Ugleda na zidu crvenu ružicu i pomisli da će je dodirnuti, ali ona se smiješi samo sa slike. Zato je dohvati i donese u selo. Odnese ju je župniku.

On reče da je to slika neke princeze iz davnine i da se može otvoriti samo srebroključem. I da se u njoj krije blago koje je davno bilo ukradeno. Svećenik joj ispričuvijeda da je ona princeza bila u ljubavi s viteзом. On je bio tako lijep da ga je svaka djevoka htjela za muža, pa je zavidna majka poslala njegovu kletvu i on je postao strašan crni pas. Princeza se pretvorila u divljakušu i pobjegla u šumu, ali

Preliminarni prompt 3

Početni tekst: Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.

Generirani nastavak

Pismo nije bilo dugačko:

Dragi brate! Na žalost moram ti priopćiti da je moja draga umrla jučer uvečer. Sahranjena je danas na groblju svetog Roka. Ako ćeš doći, pođi u gradsku vjećnicu pa pitaj gdje je bio sprovod. Živ sam još. Doći ću k tebi čim se malo oporavim. Ostani mi vjeran kao i dosada. Od tvog Franje.

Franji su suze potekle na oči i on ih je skrivao rukama. Onda je ustao, zatvorio vrata od sobe i izašao van. Nije imao ni volje ni snage da se obrije, već je takav otišao u gostionicu. U gradu ga nitko nije vidio. Čitave tri godine nije dolazio. Njegova rodbina u gradu znala je za njega, ali mu nikako nisu mogli ući u trag. Tek poslije mjesec dana došao je jedan stari znanac da

Preliminarni prompt 4

Početni tekst: Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen. Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.

Generirani nastavak

Kad su ih ljudi vidjeli, bili su u strahu jer nisam ni na kakvoj stazi, već negdje u grmlju, a to se ne smije čuti.

Neko su se vrijeme bojali, ali kada bi zvonjava prestala, oni bi opet bacali drvlje i kamenje u gustiš i tako svaki dan. I samo je jedan čovjek rekao: „Ako ostanemo bez hrane, možda će nam taj jelen pomoći.” Sutradan su ga ostavili samog u šumi, a on je stvarno donio hranu. Onda su ga odveli kući i postavili ga za stolom, ali je on pobjegao, a hrana mu je ostala. Od tada se više nije pojavljivao.

Preliminarni prompt 5

Početni tekst: Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.

Generirani nastavak

Kad su napokon došli na peron, neki muškarci zviždali su i pljeskali. Vojnik je ustao, otpozdravio i odmahnuo rukom, kao da im se ruga.

U vagonu je bilo toplo i mirisalo po drvetu i benzinu. Djevojka je sjedila pokraj prozora, a vojnički je kaput bio bačen preko nasuprotne klupe. Trgovac je izvadio veliku kariranu torbu i smjestio je ispod sjedišta, pa je potom izvukao boce iz nje, stavio ih pred sebe na klupu i pokrio kovčege dekom. Sve troje bili su tiho, kako bi uopće moglo biti tiše.

Samo što je vlak krenuo, djevojku je pozvao telefonski glas: „Gospođice Mihalinec?” Ona se okrenula i rekla: „Da, ja sam.” Glas je bio oštar, a ipak lagan i umoran. „Teta Anka... Teta Ankica!” Glas je opet

Preliminarni prompt 6

Početni tekst: Uoči svadbe Ana je u majčinoj škrinji pronašla izblijedjelu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Generirani nastavak

Kada su se sreli, mladić joj reče da ga je ona čekala i prije 10 godina, a njegovu suprugu Ana nazva nepoželjnom.

Epoha 8 (checkpoint-3392)

Preliminarni prompt 1

Početni tekst: Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.

Generirani nastavak

Krenuo je dalje do obližnjeg dvorca i ugledao kako gori crvena svjetiljka. Ušavši unutra, nađe u velikoj dvorani nekoliko staraca i jednu staricu, koji su pjevali i plesali oko stola. Na čelu svega sjedio je grof i njegov sin, a uz njih lijepa mlada žena.

- „Gdje je moja majka?” - upita Marko.

- Grofova kći, reče mu sin.

Zatim im pripovijedi kako je izgubila pamet od straha, te da ga je napustila u šumi.

A onda nastavi:

- “Nije istina! Sada sam vidio vašu majku kod grofa. Ona je lijepša negoli sam je ikada vidio. Kako ste mogli reći da joj je um pomućen? Mora da ju je otac silom doveo kod vas, jer ona nije htjela da ide.”

- To je istina, potvrdi starica.

Sve se to dogodilo za vrijeme lova.

Preliminarni prompt 2

Početni tekst: Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.

Generirani nastavak

Kad ga je uzela i stavila u džep, zacvilela je kao da joj je netko otrgnuo komadić srca.

- Bako! - viknuo je mali Vuk. - Vidi što sam našao!

Baka je dohvatila kantu i počela brisati pod, a Vuk je ostao nasred dvorišta držeći u rukama srebro. Odjednom je baki ispao lončić iz ruke. Poletio je u zrak i razbio se o tlo. Nastala je grozna galama. Čula se pogrdna riječ „prokletstvo”. Svi su se zagledali u maloga Vuka. Prišli su mu i pitali ga odakle mu taj ključ.

- A gdje si ga našla? - zapitao je baku.

Djevojčce se sakrilo iza majke. Oko njenih nogu ležao je razbijeni lončić. Majka je plakala i vikala:

- Zlotvoru! Što ćemo sad?
- Tako mi je žao, draga mo

Preliminarni prompt 3

Početni tekst: Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.

Generirani nastavak

Pismo nije bilo dugačko:

Dragi brate! Na žalost moram ti priopćiti da je moja draga umrla jučer uvečer. Sahranjena je danas na groblju svetog Roka. Ako ćeš doći, pođi u gradsku vječnicu pa pitaj gdje je bio sprovod. Živ sam još. Doći ću k tebi čim se malo oporavim. Ostani mi vjeran kao i dosada. Od tvog Franje.

Franji su suze potekle na oči i on ih je skrivao rukama. Onda je ustao, zatvorio vrata od sobe i izišao van. Htio je da ga nitko ne vidi kako plače.

Izišavši na dvorište, osjeti da mu je srce lakše. Tek sad počeo je razmišljati što čemu dalje biti. U njegovoj kući ostala je samo mala sestra, koja nije imala ni deset godina. Nije imao više nikoga, osim str

Preliminarni prompt 4

Početni tekst: Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen. Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.

Generirani nastavak

Kad su seljani došli u šumu, vidjeli su kako čopor pasa trga jelena.

Bijela lica i ruku, okruglasta, u oblinama, stajala je pred njim. Ispod crvenog plašta nazirao se tijesan, svileni kostim. Pored nje ležalo je dijete. Dok je on gledao tu sliku, činilo mu se da je cijela ta spavaonica preobražena u veliko cvijeće koje miriše na med.

- Da! - reče djevojka i nasloni glavu na njegovo rame. - Ti si prvi, ti ćeš biti otac mom sinu.

Naš je susret bio suđen, jer sam te tražila po cijelom svijetu. Sada ćemo živjeti zajedno u sreći. Ti me moraš voljeti, ja ću tebe voljet više nego sunce nebo...

- Ne! - kliknu mladić i baci se u ognjeno more. - Ja sam samo sanjar i sanjam samo noći kad mi se sn

Preliminarni prompt 5

Početni tekst: Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.

Generirani nastavak

Kad su napokon došli na peron, neki muškarci zviždahu za djevojkom u bijelom kaputu. Stajala je na rubu kolosijeka i gledala ravno pred sebe.

- Zdravo! - reče mladić. Djevojka nije ni trepnula.

- Ti si iz Zagreba? - upita je on dalje. Ona stade okretati glavu. Odjednom je baci prema njemu. U njenim očima bljesnuše suze.

Mladić se smrknu.

Zatim pogleda u svoju torbu. Izvadi dvije karte. Jedna je imala napisan broj osam, druga devet. Na poledini obiju pisalo je: Varaždin.

Djevojku još više zaprepastiše njegove riječi. Ustukne. Mladić joj pođe ususret. Sada je i ona vidjela da je nosio torbu na ramenu. Ispod kaputa je bio odjeven u uniformu. Pruži ruku i predstavi se.

Nikola...

Dobra ve

Preliminarni prompt 6

Početni tekst: Uoči svadbe Ana je u majčinoj škrinji pronašla izbljednulu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Generirani nastavak

Kada su se sreli, mladić joj reče da ga je ona čekala i prije 10 godina, a njegovu suprugu Ana nazva nepoželjnom uljezicom...

Budite prvi koji će recenzirati "Zaručnica" Otkazi odgovor

Epoha 9 (checkpoint-3816)

Preliminarni prompt 1

Početni tekst: Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.

Generirani nastavak

Krenuo je dalje do obližnjeg sela, gdje mu je živio rođak Ivan.

Za njim su išle čitave povorke djevojaka i mladića, koji su ga pozdravljali, smijali se i izvikivali: „Marko, majstore!”

Iako je bio samo nekoliko koraka ispred njih, Markovu pogledu nije promakla niti jedna riječ, pa ni ona najtiša šaputanja. Nekoliko puta je zaustavio povorku i upitao da li mu netko nešto reče, ali nije bilo odgovora. Uskoro je stigao pred brzinom ceste, gospodski podignute glave, kao da je baš tu rođen.

Ivanova žena Jana pokazala mu je sobu u kojoj će spavati. Tamo ga je već čekalo nekoliko praznih kreveta, puno prašine, pljesnive zidove i krov pun rupa. Soba je, naime, služila za skladište krumpira, jabuka i

Preliminarni prompt 2

Početni tekst: Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.

Generirani nastavak

Kad ga je uzela i stavila pod nos, čula je malu škripu i osjetila miris zlatnih žita.

Uzela je ključ i pošla u grad. Sve do grada imao je putić pun rupa, ali ona je brzo hodala i za kratko vrijeme našla se u gradu.

Taj je bio veći nego ikada prije. Bio je toliko velik da se u njega moglo stati bezbroj ljudi. I svi ti ljude bili su krasni i lijepi.

Zatvorila je oči i gledala ih. Nije znala gdje bi prvo pogledala, jer su joj se sve boje ispred očiju mijenjale, a svaki put kad bi otvorila oči, vidjela bi neki drugi dio grada.

I tako je dugo tražila ključeve, dok se nije umorila. No i dalje je htjela da nađe one koji će joj otvoriti vrata. Ali nije ih nalazila. Odjednom se pred njom stvoriše tri vrata, sva od

Preliminarni prompt 3

Početni tekst: Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.

Generirani nastavak

Pismo nije bilo dugačko:

Dragi brate! Na žalost moram ti priopćiti da je moja draga žena umrla. Molim te dođi u grad i pomoz mi da se sve pripremi za pokojnicu. Ti znaš da sam ja siromašan i da nemam snage ni mogućnosti da sve to sam izvedem.

Pisaše mu na kraju: „I ne brini se o meni! Ja ću se za sebe pobrinuti. Nemam djece.”

Svoje je pismo poslao i uredniku novina gdje je radio:

„Poštovani gospodine! Vaš je čitatelj Franjo Kovačić. Nisam imao prilike, a i neću vam reći šta me potaklo da vam pišem. No jedno vas molim: objavite ovih nekoliko redaka u vašim novinama. To će biti najljepši spomen na onu koja je uvijek slušala i čitala vaše listove.

Vaš čitatelj F. Kovačić.”

Kako su

Preliminarni prompt 4

Početni tekst: Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen. Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.

Generirani nastavak

Kad su ih ljudi vidjeli, bili su u strahu jer nisam ni na kakvoj stazi, već negdje u grmlju, a to se ne smije čuti.

Neko su se vrijeme bojali, ali kada bi zvonjava prestala, oni bi opet bacali drva i sijeno u jamu.

I tako iz dana u dan, samo što su se sada svi skupili i gledali. Tko će prvi baciti koju cjepanicu? Ipak se nitko nije usudio prvi početi, jer svatko je očekivao od drugih da počnu prvi, pa ćemo tako doznati tko je od nas najhrabriji. Tako su prošla tri dana, a onda je došlo do dogovora. Bilo je odlučeno da ćete vi, mladiću, bacati prve cjepanice, i mi ćemosvaki put pljeskati.

Kad ste vi bacili prvu cijepanici, počеше se i drugi bacanjati, i oni što nisubili baš pr

Preliminarni prompt 5

Početni tekst: Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.

Generirani nastavak

Kad su napokon došli na peron, neki muškarci zviždahu za djevojkama.

Svi putnici bili su se ukrcavali u isti vagon, pa i vojnička pratnja iz grada. Vojnik je imao dvadeset godina, a bio je visok, mršav i plav. Vozio se kući u selo, gdje će ga sačekati majka. Tamo ćemo ti ja i moja žena biti domaćini - reče mu jedan od stražara. Onda pogledaše u njega ozbiljno: - Jesi li pojeo? Ponesi si malo kruha, nemoj ništa jesti podne. I oprezno! Štajerske planine pune su partizana!

Začudio se što mu govore tako strogo, ali ipak htjedne da bude poslušan. No prije negoli se ukrcali u vlak, moradoše još i po polju trčati. Stigli su u selu i upitali ljude jesu li vidjeli partizane. Nis

Preliminarni prompt 6

Početni tekst: Uoči svadbe Ana je u majčinoj škrinji pronašla izblijedjelu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Generirani nastavak

Kada su se sreli, mladić joj reče da ga je ona čekala i prije 10 godina, a njegovu suprugu Ana nazva nepoželjnom uljezicom...

Budite prvi koji će recenzirati "Zaručnica" Otkazi odgovor

Epoha 10 (checkpoint-4240)

Preliminarni prompt 1

Početni tekst: Kad se nakon dvadeset godina vratio u rodno selo, Marko je zatekao očevu kuću zaključanu, a na pragu svježe otiske blatnih cipela.

Generirani nastavak

Krenuo je dalje i stigao do groblja. Tamo je vidio čovjeka kako sjedne uz njegova oca, izvadi novine i počne ih čitati.

- Alo! - poviknu Marko, ali mu ne odgovoriše ništa. Ljutito uđe u crkvicu i ugleda dvoje ljudi kako kleče pred oltarom. I on klekne za njima i prekriži se.

- Oprostite mi, draga moja majko - reče tiho - što sam vas ostavio i što vas nisam posjećivao. Vratit ću se ja opet, obećavam vam...

Vrati se natrag, prođe pored groba, a tamo ugrijevnu sunce. Učini mu se da ga grije topli dah očeva i majčina. Okrene se, ali na prilazu ne bijaše više nikoga.

Preliminarni prompt 2

Početni tekst: Na proštenju pod starim lipama svirala je glazba, trgovci su glasno nudili robu, a djevojčica je među kamenjem ugledala srebrni ključ.

Generirani nastavak

Kad ga je uzela i stavila u džep, zacvilela je kao da joj je netko otrgnuo komadić srca.

- Gdje si ga našla? - upitao ju je otac.

- Nisam ga naćula, nego sam ga kupila od onoga čovjeka što prodaje igračke!

- Zašto si mu novce dala za taj ključić? - zapitao je otpočinjući prema siniji.

Djevojka se zacrvenjela i rekla:

- Htjela sam da ga imam...

Otac je bio ljutit, ali ipak je rekao:

Prije 30 godina bilo je proštejnje pod starom lipom, gdje je sad pruga. Moj je djed živio kraj te lipe, a ja sam sada tu rodila tri kćerke. Jedna je od njih dobila ime po staroj liji, druga po mojoj majci, a treća po babi.

Preliminarni prompt 3

Početni tekst: Gospodin Franjo cijeloga je jutra sjedio uz zatvoren prozor i držao neotvoreno pismo. Kad je sat otkucao podne, napokon je prelomio pečat.

Generirani nastavak

Pismo nije bilo dugačko:

Dragi brate! Na žalost moram ti priopćiti da je moja draga žena umrla. Molim te dođi u grad i pođi sa mnom na groblje.

Tvoj brat Franjo.

Zatim je još dodao: „Pa i ja sam star, pa ćemo i mi skupa!”

Napokon se spremio i izišao van. Htio je otići na grob, ali ga put odvede u krčmu. Tamo je popio nekoliko pića, a poslije mu se pridružila još jedna gospođa u crnini.

Imao je osjećaj kao da je ponovno sa sestrom, štoviše, kao u vrijeme kad su još bili djeca.

Bile su si tako bliske i zajedničke. Neko su vrijeme razgovarali o pokojnoj majci, onda su otišle na grobiće i tamo plakale.

Kad su se uveče vratile doma, primijetile su da im je nestalo novaca, ali

Preliminarni prompt 4

Početni tekst: Stara je žena govorila da se na raskrižju poslije ponoći pojavljuje bijeli jelen.

Nitko joj nije vjerovao sve dok se jedne zime iz šume nisu začula zvona.

Generirani nastavak

Kad su ih ljudi vidjeli, bili su u strahu i kada je došla jutarnja svjetlost, nikog više nije bilo.

Ubrzo se pročulo da su se dva lovca prepali neobičnog prizora i da su pobijedili glavom od drveta koja je bila ukrašena rogovima jelena. I od tada se više nitko nije usudio doći na raspelo u šumi.

Preliminarni prompt 5

Početni tekst: Vlak je kasnio tri sata, a u čekaonici su ostali samo mladi vojnik, trgovac s kožnim kovčegom i šutljiva žena u crnini.

Generirani nastavak

Kad su napokon došli na peron, neki muškarci zviždahu za djevojkom u bijelom kaputu.

Stajala je na kolodvoru, uzdignute glave i ozbiljna lica, ali se ipak smiješila.

Zastao je iza drvene klupice i gledao je. Bilo joj je osamnaest godina i bila je najljepša djevica u selu. U njezinoj dugoj crnoj kosi blistalo je sunce kao da je od čiste zlatne žice. Na njenim crnim očima sjajile su se velike plave, nebeske oči, a crvene usnice podrhtavale su

od uzbuđenja. Sada je bila u bijelo obučena, ali je prije toga nosila svijetlu haljinu. Kako ju je lijepo vidjeti u bijele rukavice! Mora da je jako hladno u gradu, jer u njenu licu kao u ledu vidi se da je strašno studeno. A kako je samo bila sretna onda kad je odlazila iz sela

Preliminarni prompt 6

Početni tekst: Uoči svadbe Ana je u majčinoj škrinji pronašla izblijedjelu fotografiju na kojoj je uz njezina zaručnika stajala nepoznata djevojka.

Generirani nastavak

Kada su se sreli, mladić joj reče da ga je ona čekala i prije 10 godina, a njegovu suprugu Ana nazva nepoželjnom uljezicom...

- Nisam bila ni kriva ni dužna! - kaže Ana.

Sutradan ju je muž ostavio i otišao za onom nepozantom djevokom. Zato je došla u Zagreb i ustupila stan majci da bi živjela u nekom drugom gradu.

Iako je imala novaca, Ani je trebalo puno vremena dok nije postala zadovoljna svojim poslom, pa je tako tek krajem prošle godine odlučila da će se udati.

Kada je to rekla majci, ona je zaplakala: „Zar ti nisi sretna sa mnom?” Na to je Ana odgovorila: „Nisam!” I majka ju je pustila da ode.

- Sad mi je dobro - kaže Ana - ali me ipak muči pitanje što sam bila tako jalova, što nisam mogla biti